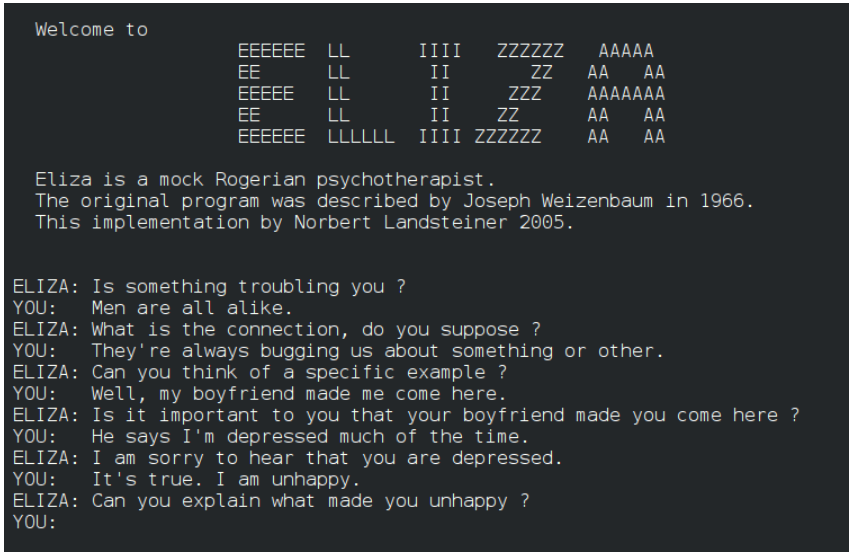
# Introducción al Procesamiento de Lenguaje Natural

Clase 1 · Procesamiento de Lenguaje Natural

Andrés Abeliuk · Fabrizzio Pezzolla

Diplomado en Inteligencia Artificial · DCC · Universidad de Chile

# De ELIZA a los asistentes de hoy




*ELIZA (Weizenbaum, 1966), implementación de N. Landsteiner.*

**1966 · ELIZA**

Imita a un psicoterapeuta reformulando lo que escribe el usuario con patrones. No entiende nada.

**2026 · Asistentes con LLMs**

Conversan, resumen, traducen, programan, razonan paso a paso y usan herramientas.

**Sesenta años de NLP: de escribir reglas a mano a aprender el lenguaje desde los datos**

# Qué vamos a poder explicar

01 Qué es el NLP y por qué el lenguaje es difícil para un computador

02 Los niveles de análisis lingüístico: de los sonidos a la intención

03 Cómo evolucionó el NLP: reglas, aprendizaje automático, deep learning y LLMs

04 Qué tareas resuelve hoy el NLP y cómo se organiza este curso

# ¿Qué es el NLP?

El Procesamiento de Lenguaje Natural (NLP) es la rama de la inteligencia artificial que permite a los computadores **procesar, comprender y generar lenguaje humano**, escrito o hablado.

### Comprender

Extraer de qué habla un texto, quién aparece y qué opina.

### Generar

Redactar, responder, resumir o completar texto.

### Transformar

Traducir entre idiomas o convertir voz en texto y texto en voz.

Combina **lingüística computacional**, **aprendizaje automático** e **ingeniería de software**.

# El texto es un dato no estructurado

### Datos estructurados

Modelo de datos conocido: filas y columnas en bases relacionales o planillas.

### Datos no estructurados

Sin esquema, ambiguos e irregulares: texto libre, audio, imágenes, PDF.

**El NLP convierte texto libre en datos que se pueden analizar**

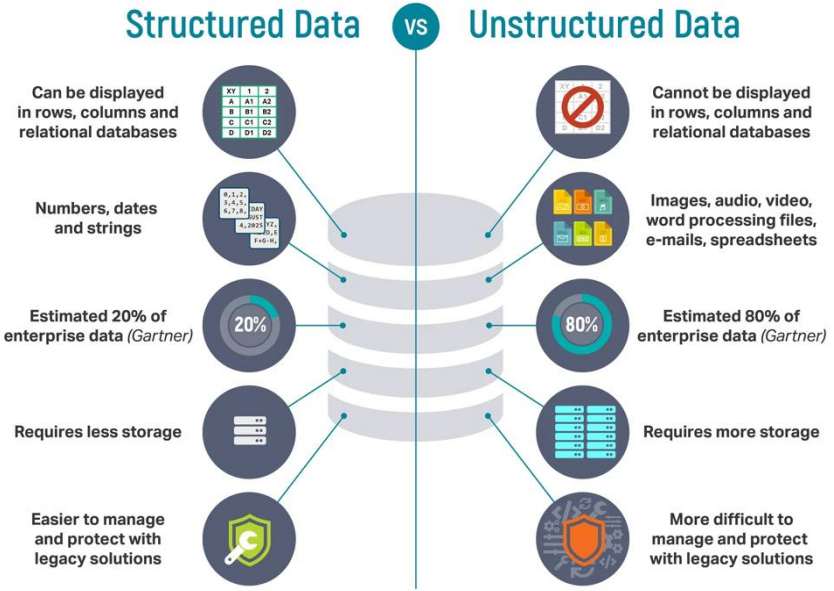



*Figura: lawtomated.com, Structured data vs unstructured data.*

# ¿Por qué es difícil?

El lenguaje es ambiguo, variable y depende del contexto

# Una oración, dos significados

*“Vi a la persona con el telescopio”*

**Lectura 1: instrumento**

Yo usé el telescopio para ver a la persona.

**Lectura 2: atributo**

La persona que vi tenía un telescopio.

**Las personas desambiguamos con contexto y conocimiento del mundo. Un sistema de NLP tiene que aprenderlo.**

# Seis fuentes de dificultad

### Ambigüedad

Palabras y estructuras con más de una lectura: “banco”, “vela”.

### Variación

Dialectos, jerga y registro: “¿cachai?”, “al tiro”, “po”.

### Ruido

Errores, abreviaciones y emojis: “q onda, nos vmos mñn”.

### Ironía

“Excelente, otra vez sin luz” no es una opinión positiva.

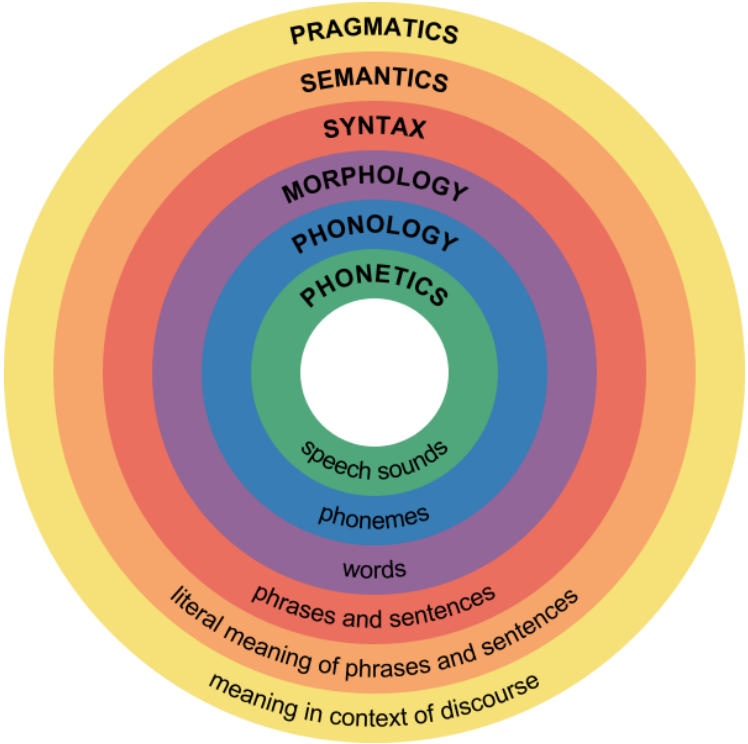
### Conocimiento del mundo

“No cupo en la maleta porque era muy grande”: ¿qué era grande?

### Dominio e idioma

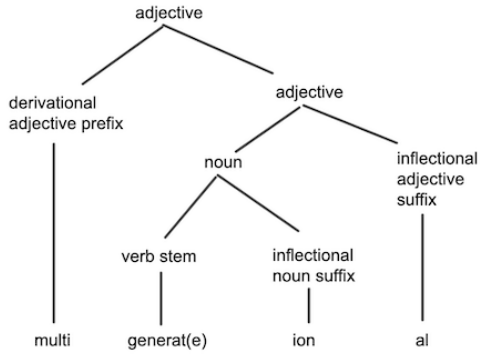
Lo que funciona en noticias falla en fichas clínicas; el español tiene menos recursos que el inglés.

# Niveles de análisis lingüístico



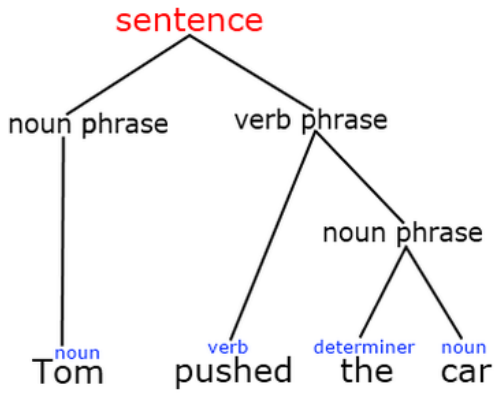

| | |
|---|---|
| **Fonología** | “casa” y “caza” suenan igual en Chile: el contexto decide |
| **Morfología** | “corr-iendo”, “corr-edor”: la misma raíz con distintos afijos |
| **Sintaxis** | “María ama a Pedro” ≠ “Pedro ama a María”: el orden importa |
| **Semántica** | “banco”: ¿asiento o institución financiera? |
| **Pragmática** | “¿Me pasas la sal?” es una petición, no una pregunta |

# Morfología y sintaxis: la estructura




## Morfología

Las palabras se forman con morfemas: raíz + afijos. Lematizar: “corriendo” → “correr”.




## Sintaxis

Las palabras se agrupan en constituyentes: sintagma nominal, verbal. El parser recupera ese árbol.

# Semántica y pragmática: el significado

## Semántica

- “Me senté en el **banco** de la plaza”
- “Pedí un crédito en el **banco**”
- Misma palabra, distinto sentido. Los embeddings contextuales (clase 5) lo resuelven.

## Pragmática

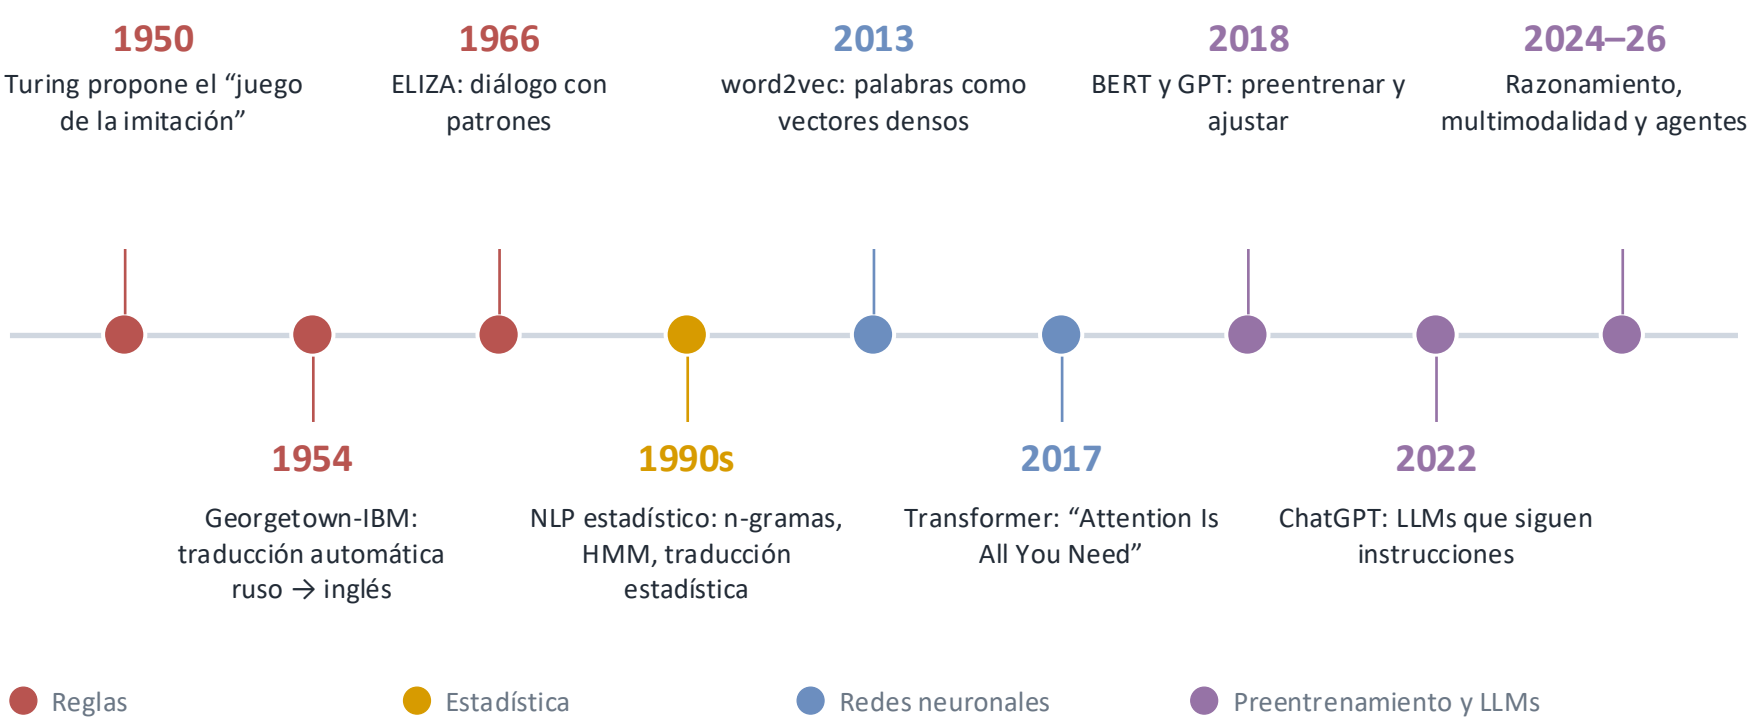
- “¿Puedes pasarme la sal?” **pide** algo; no pregunta por tu capacidad
- “Qué buena idea…” puede ser un elogio o una burla
- Depende de quién habla, a quién y en qué situación.

**Cada nivel da origen a tareas de NLP: lematización, análisis sintáctico, desambiguación y detección de intención**

# Cómo evolucionó el NLP

De reglas escritas a mano a modelos que aprenden de billones de palabras

# Setenta años en una línea



# Cuatro paradigmas

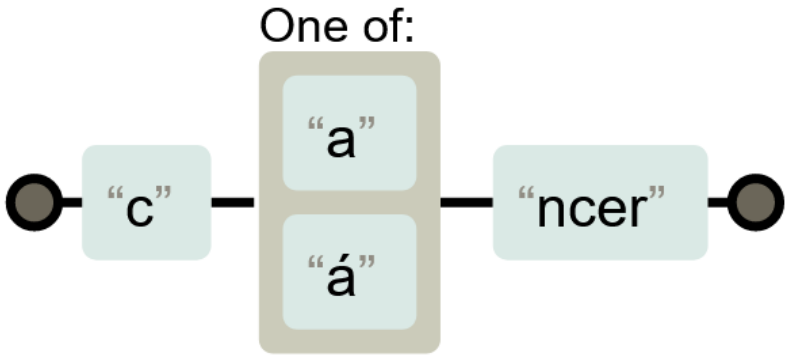
| | Reglas | ML clásico | Deep learning | LLMs |
|---|---|---|---|---|
| **Quién define las características** | Un experto escribe patrones | Un ingeniero diseña features (TF-IDF, n-gramas) | La red las aprende desde texto crudo | Un modelo preentrenado ya las trae |
| **Datos etiquetados** | Ninguno | Miles | Decenas de miles | Pocos o ninguno (prompting) |
| **Ventaja** | Transparente y controlable | Barato y robusto | Alto desempeño | Versátil: una sola herramienta para muchas tareas |
| **Límite** | Frágil, no escala | Features costosas de diseñar | Datos y cómputo | Costo, alucinaciones, opacidad |

*Las cifras de datos etiquetados son órdenes de magnitud típicos, no reglas.*

# Reglas: expresiones regulares

- Paradigma clásico de programación: un desarrollador escribe reglas que imitan el comportamiento deseado.
- La herramienta más usada son las expresiones regulares: patrones para buscar en cadenas de texto.
- **Ejemplo:** ¿en cuántas fichas clínicas se menciona cáncer?
- **Límite:** cada excepción es una regla nueva (“CA de mama”, “neoplasia”…).

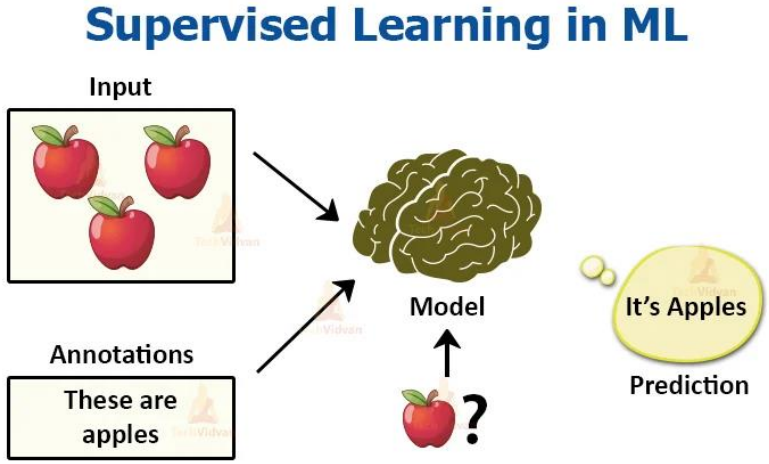
```
import re
re.findall(r"c[aá]ncer", texto, re.I)
```




*c[aá]ncer acepta “cancer” y “cáncer”.*

# Aprendizaje automático: aprender la regla

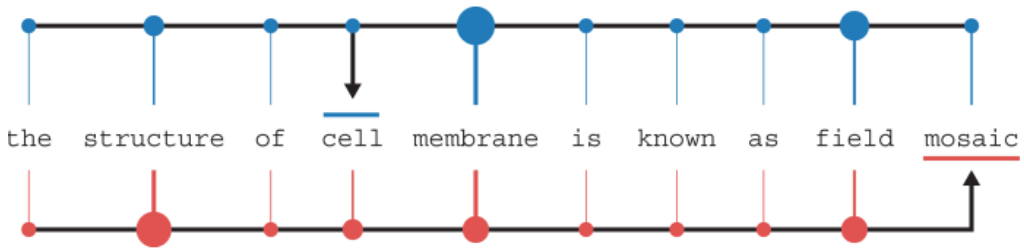
- En vez de escribir la regla, damos ejemplos etiquetados y un algoritmo aprende la función.
- **Pero:** el modelo no lee texto; necesita características numéricas.
- **Ingeniería de características:** conteos de palabras, n-gramas, largo, mayúsculas, palabras de un léxico.




**El cuello de botella: diseñar buenas características requiere conocimiento del dominio e intuición**

# Deep learning: aprender la representación

- Las redes neuronales aprenden automáticamente las características relevantes desde el texto.
- **Embeddings** (clase 3): palabras como vectores densos.
- **Redes recurrentes** (clase 4): leen el texto en secuencia.
- **Transformers** (clase 5): la autoatención conecta palabras lejanas en paralelo.

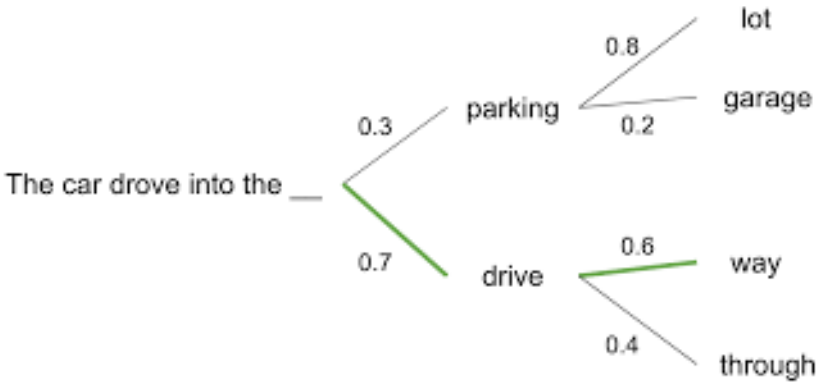



*Para predecir "mosaic", el modelo se apoya en palabras lejanas como "cell" y "membrane".*

# Modelos de lenguaje: ¿qué palabra sigue?

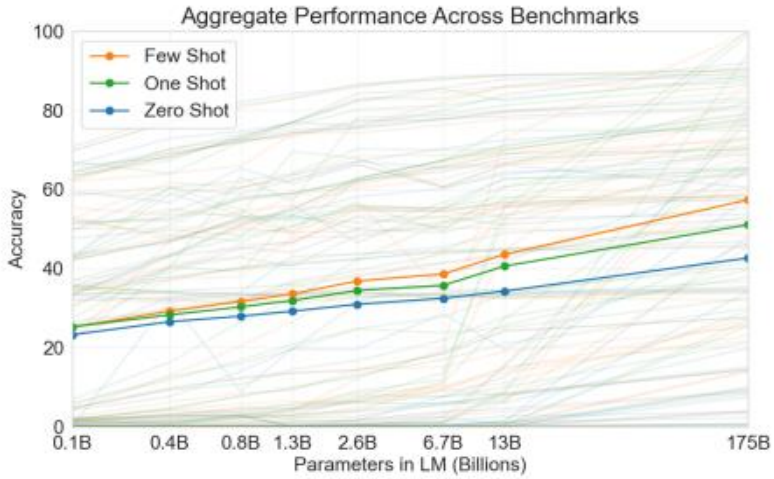
$$P(w_n \mid w_1, \ldots, w_{n-1})$$

- Un modelo de lenguaje asigna una probabilidad a cada palabra dado su contexto.
- Para generar, elige una palabra, la agrega al contexto y repite: generación autoregresiva.
- Es la misma idea del autocompletado del celular, a una escala enorme.




**Predecir bien la siguiente palabra obliga a aprender gramática, hechos del mundo y algo de razonamiento**

# La escala cambia las reglas




- **Leyes de escala:** más parámetros, datos y cómputo dan mejor desempeño, de forma predecible.
- **Aprendizaje en contexto:** el modelo resuelve tareas nuevas con ejemplos en el prompt (zero-/few-shot).
- **Instrucciones y RLHF:** el ajuste con preferencias humanas convierte un modelo en asistente.
- **¿Habilidades emergentes?** Debate abierto: en parte dependen de la métrica (Schaeffer et al., 2023).

*Fuente: Brown et al. (2020), Language Models are Few-Shot Learners.*

# El NLP en 2026

### Razonamiento

Modelos que “piensan” antes de responder, gastando más cómputo en inferencia.

### Multimodalidad

Texto, imagen, audio y video en un mismo modelo.

### Agentes

Usan herramientas, buscan, ejecutan código y encadenan pasos.

### RAG

Responder con documentos propios para reducir alucinaciones.

### Modelos abiertos

Llama, Qwen, Mistral, DeepSeek o Gemma: se ajustan y despliegan localmente.

### Eficiencia

Cuantización y LoRA para usar y ajustar modelos con poco hardware.

*Todo esto se apoya en los fundamentos del curso: tokens, embeddings, atención y preentrenamiento.*

# ¿Sigue importando el NLP clásico?

### Conviene un LLM cuando…

- La tarea es abierta o hay que generar texto
- Hay pocas o ninguna etiqueta
- Se necesita un prototipo rápido

### Conviene un método clásico cuando…

- La tarea es acotada y  bien definida
- Hay millones de documentos y el costo importa
- Se necesita explicar y auditar la decisión
- Los datos sensibles no pueden salir de la institución

**Regla práctica: parte con un baseline simple, mide, y escala solo si la mejora lo justifica**

# Tareas del NLP

Qué problemas resolvemos con texto y voz

# Un mapa de tareas

### Comprensión

- Clasificación
- Sentimiento
- Entidades (NER)
- Extracción de información
- Preguntas y respuestas

### Generación

- Resumen
- Traducción
- Diálogo
- Redacción y código

### Voz

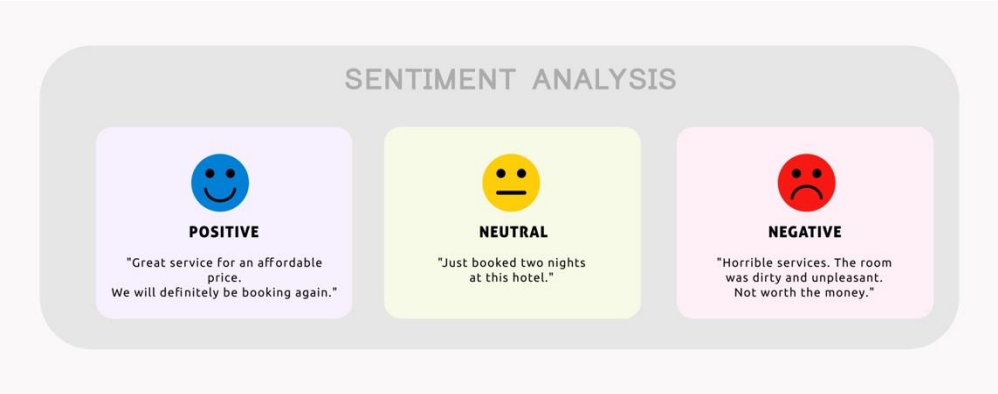
- Reconocimiento del habla (ASR)
- Síntesis de voz (TTS)

### Multimodal

- Texto → imagen
- Descripción de imágenes
- Documentos escaneados

# Clasificación de texto

Asignar una o más categorías a un texto libre. Es la tarea más común en la industria.




*Análisis de sentimiento: positivo, neutro o negativo.*

- Spam / no spam
- Tema de una noticia
- Sentimiento de una reseña
- Urgencia de un reclamo
- Código CIE-10 de un diagnóstico

# Reconocimiento de entidades nombradas

Localizar entidades en un texto y clasificarlas en categorías: persona, organización, lugar, fecha… o las de un dominio.




*Entidades en una ficha clínica en español: edad, fecha, ocupación, institución.*

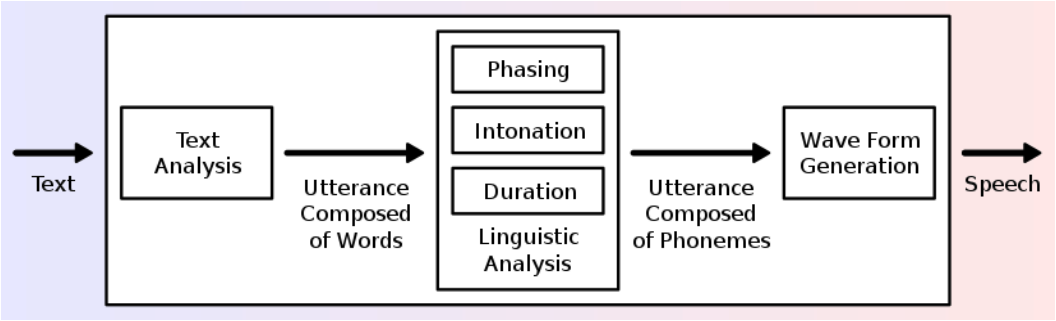
# Voz: reconocer y sintetizar

### Reconocimiento (ASR)

Voz → texto. Procesa la señal de audio y la decodifica como una secuencia de palabras.

### Síntesis (TTS)

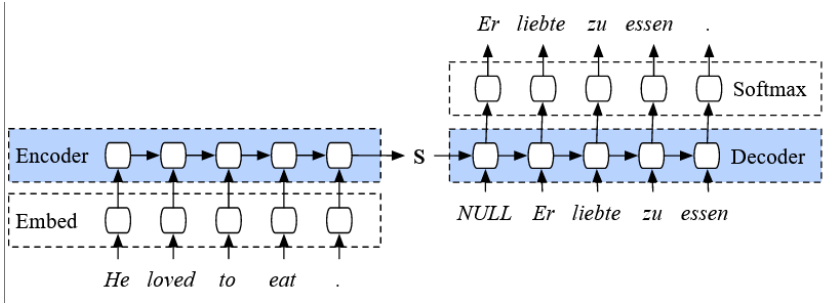
Texto → voz. Reconstruye la señal de audio que corresponde a un texto.




*Pipeline clásico de síntesis de voz. Hoy ambas tareas se resuelven de extremo a extremo con redes neuronales.*

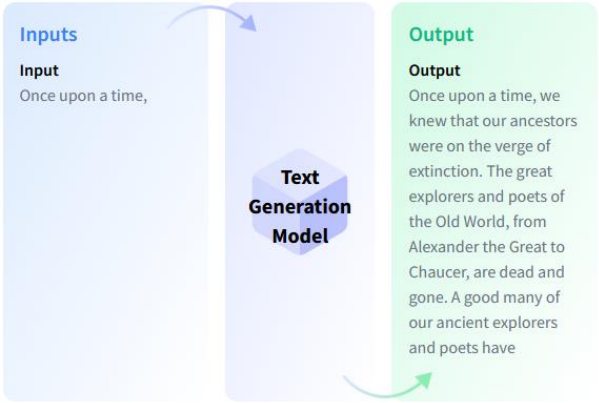
# Traducción automática

- Convierte una secuencia de palabras de un idioma a otro.
- **Secuencia a secuencia:** un codificador representa el significado y un decodificador lo reconstruye en otro idioma.
- El Transformer nació en 2017 justamente para traducir.
- Hoy los LLMs traducen entre cientos de idiomas, pero rinden peor en lenguas con pocos datos, como el mapudungun.



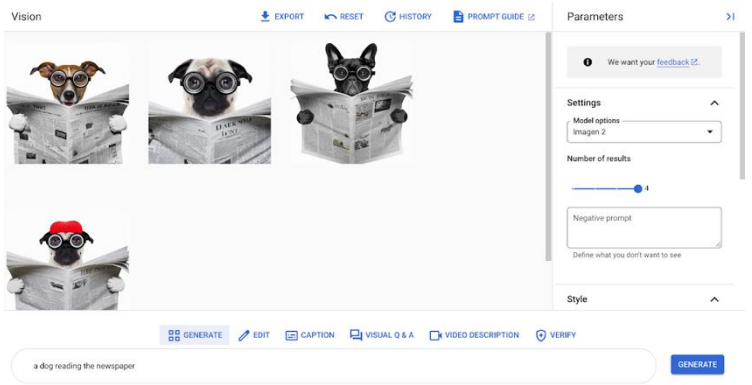

*Codificador–decodificador: "He loved to eat" → "Er liebte zu essen".*

# Generación de texto e imágenes




## Texto

El modelo completa la secuencia palabra a palabra a partir de un inicio (prompt).




## Imágenes

Un modelo de lenguaje codifica la descripción y un modelo generativo produce la imagen.

# Ética y riesgos

### Sesgos

Los modelos aprenden estereotipos de los datos: “el doctor”, “la enfermera”.

### Alucinaciones

Respuestas fluidas pero falsas: datos y citas inventadas.

### Desinformación

Texto, voz y video sintéticos a escala: bots y deepfakes.

### Privacidad

Datos personales en el entrenamiento y en los prompts. En Chile, Ley 21.719.

### Trabajo

Automatización de redacción, traducción y atención; nuevas habilidades.

### Costo ambiental

Energía y agua para entrenar y servir modelos grandes.

*Volveremos a estos temas en las clases de embeddings (sesgos) y de alineamiento de LLMs.*

# Contenido del curso

1. **Introducción y preprocesamiento**
   Tokenización, normalización, exploración
2. **Semántica vectorial**
   Bag of Words, TF-IDF
3. **Word embeddings**
   word2vec, GloVe, fastText
4. **Deep learning y redes recurrentes**
   RNN, LSTM, GRU
5. **Transformers**
   Autoatención, BERT, GPT
6. **Grandes modelos de lenguaje**
   Prompting, few-shot, habilidades emergentes
7. **Cuantización y fine-tuning eficiente**
   LoRA, QLoRA
8. **Alineamiento de LLMs**
   RLHF, DPO, GRPO

# Dinámica y evaluación

## Cada clase tiene tres partes

**Cátedra**
Conceptos y modelos

**Tutorial**
Código guiado en notebooks

**Laboratorio**
Ejercicio práctico en clase

## Evaluación

**2 tareas prácticas en grupo**

La evaluación del curso consiste en dos tareas prácticas grupales: aplicar las técnicas vistas a un problema con datos reales.

# Ahora en Python

1.1

## Preprocesamiento

Normalización · tokenización con regex · BPE y WordPiece · stemming y lematización

1.2

## Exploración

Diversidad léxica · ley de Heaps · frecuencias y nubes de palabras · TF-IDF · concordancias y bigramas