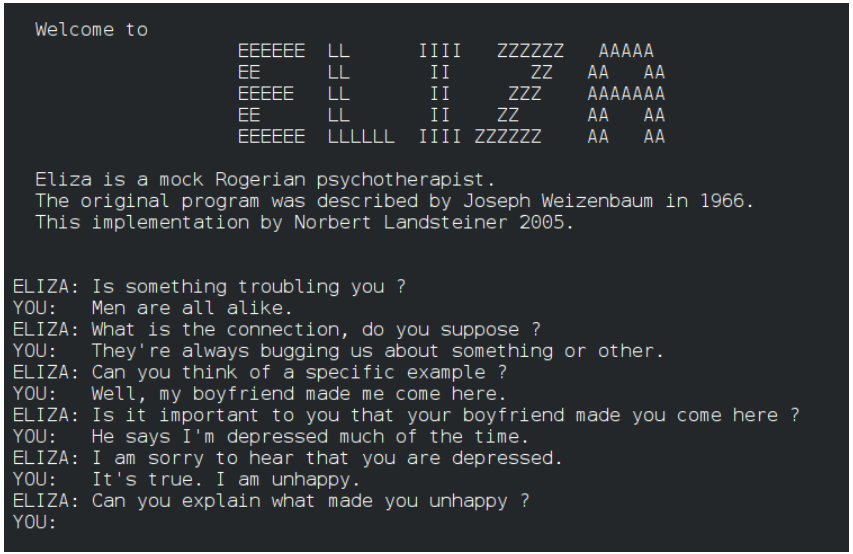
Introducción al Procesamiento de Lenguaje Natural

Clase 1 · Procesamiento de Lenguaje Natural

Andrés Abeliuk · Fabrizzio Pezzolla

Diplomado en Inteligencia Artificial · DCC · Universidad de Chile

De ELIZA a los asistentes de hoy



ELIZA (Weizenbaum, 1966), implementación de N. Landsteiner.

1966 · ELIZA

Imita a un psicoterapeuta reformulando lo que escribe el usuario con patrones. No entiende nada.

2026 · Asistentes con LLMs

Conversan, resumen, traducen, programan, razonan paso a paso y usan herramientas.

Sesenta años de NLP: de escribir reglas a mano a aprender el lenguaje desde los datos

Qué vamos a poder explicar

01 Qué es el NLP y por qué el lenguaje es difícil para un computador

02 Los niveles de análisis lingüístico: de los sonidos a la intención

03 Cómo evolucionó el NLP: reglas, aprendizaje automático, deep learning y LLMs

04 Qué tareas resuelve hoy el NLP y cómo se organiza este curso

¿Qué es el NLP?

El Procesamiento de Lenguaje Natural (NLP) es la rama de la inteligencia artificial que permite a los computadores **procesar, comprender y generar lenguaje humano**, escrito o hablado.

Comprender

Extraer de qué habla un texto, quién aparece y qué opina.

Generar

Redactar, responder, resumir o completar texto.

Transformar

Traducir entre idiomas o convertir voz en texto y texto en voz.

Combina **lingüística computacional**, **aprendizaje automático** e **ingeniería de software**.

El texto es un dato no estructurado

Datos estructurados

Modelo de datos conocido: filas y columnas en bases relacionales o planillas.

Datos no estructurados

Sin esquema, ambiguos e irregulares: texto libre, audio, imágenes, PDF.

El NLP convierte texto libre en datos que se pueden analizar

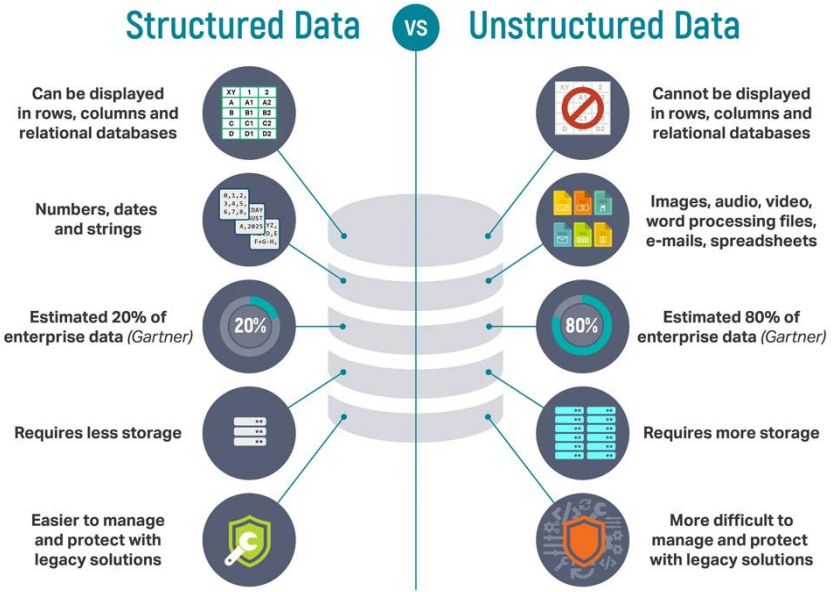


Figura: lawtomated.com, Structured data vs unstructured data.

¿Por qué es difícil?

El lenguaje es ambiguo, variable y depende del contexto

Una oración, dos significados

“Vi a la persona con el telescopio”

Lectura 1: instrumento

Yo usé el telescopio para ver a la persona.

Lectura 2: atributo

La persona que vi tenía un telescopio.

Las personas desambiguamos con contexto y conocimiento del mundo. Un sistema de NLP tiene que aprenderlo.

Seis fuentes de dificultad

Ambigüedad

Palabras y estructuras con más de una lectura: “banco”, “vela”.

Variación

Dialectos, jerga y registro: “¿cachai?”, “al tiro”, “po”.

Ruido

Errores, abreviaciones y emojis: “q onda, nos vmos mñn”.

Ironía

“Excelente, otra vez sin luz” no es una opinión positiva.

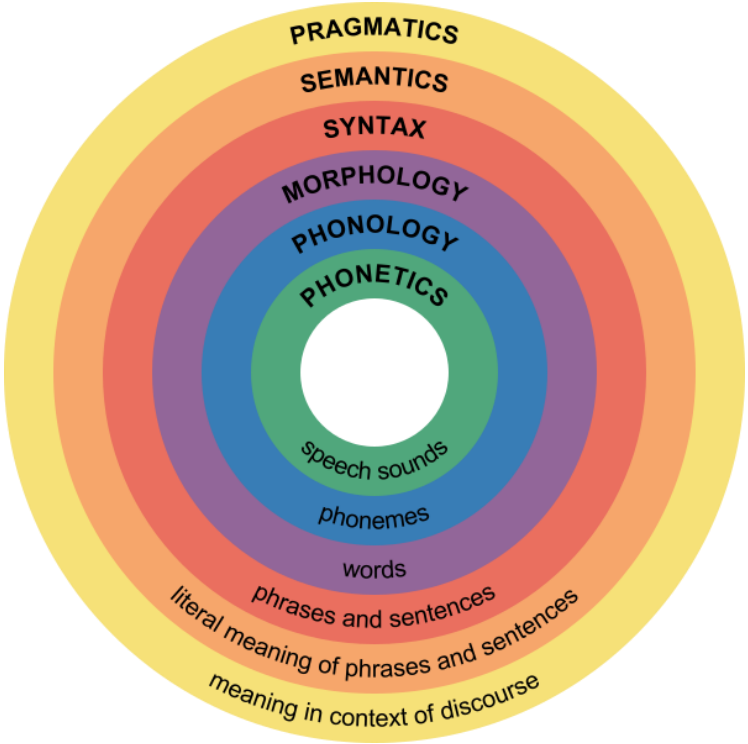
Conocimiento del mundo

“No cupo en la maleta porque era muy grande”: ¿qué era grande?

Dominio e idioma

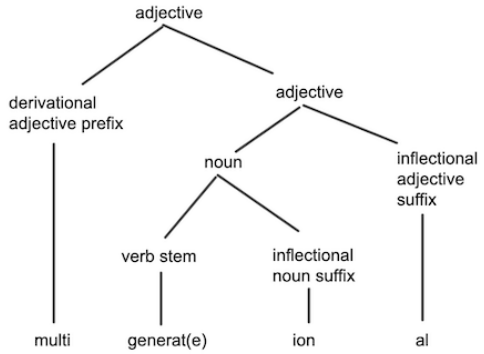
Lo que funciona en noticias falla en fichas clínicas; el español tiene menos recursos que el inglés.

Niveles de análisis lingüístico



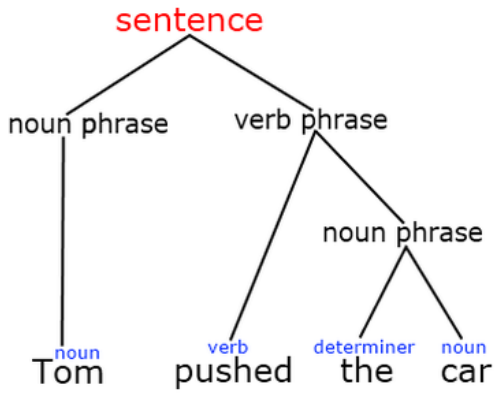
Fonología	“casa” y “caza” suenan igual en Chile: el contexto decide
Morfología	“corr-iendo”, “corr-edor”: la misma raíz con distintos afijos
Sintaxis	“María ama a Pedro” ≠ “Pedro ama a María”: el orden importa
Semántica	“banco”: ¿asiento o institución financiera?
Pragmática	“¿Me pasas la sal?” es una petición, no una pregunta

Morfología y sintaxis: la estructura



Morfología

Las palabras se forman con morfemas: raíz + afijos. Lematizar: “corriendo” → “correr”.



Sintaxis

Las palabras se agrupan en constituyentes: sintagma nominal, verbal. El parser recupera ese árbol.

Semántica y pragmática: el significado

Semántica

- “Me senté en el **banco** de la plaza”
- “Pedí un crédito en el **banco**”
- Misma palabra, distinto sentido. Los embeddings contextuales (clase 5) lo resuelven.

Pragmática

- “¿Puedes pasarme la sal?” **pide** algo; no pregunta por tu capacidad
- “Qué buena idea…” puede ser un elogio o una burla
- Depende de quién habla, a quién y en qué situación.

Cada nivel da origen a tareas de NLP: lematización, análisis sintáctico, desambiguación y detección de intención

Cómo evolucionó el NLP

De reglas escritas a mano a modelos que aprenden de billones de palabras

Setenta años en una línea

1950 — Turing propone el “juego de la imitación”

1954 — Georgetown-IBM: traducción automática ruso → inglés

1966 — ELIZA: diálogo con patrones

1990s — NLP estadístico: n-gramas, HMM, traducción estadística

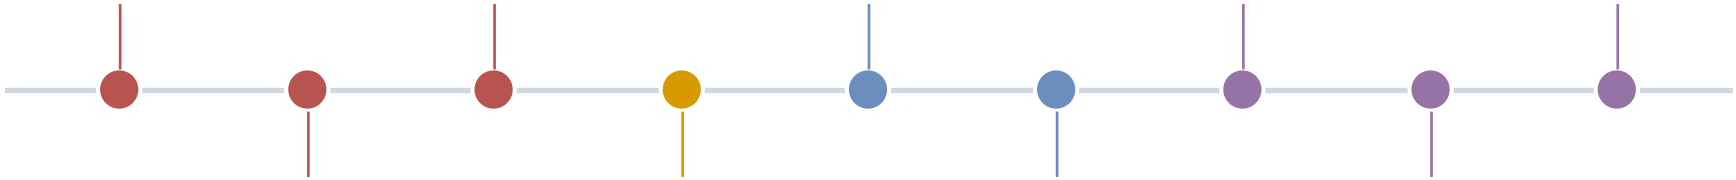
2013 — word2vec: palabras como vectores densos

2017 — Transformer: “Attention Is All You Need”

2018 — BERT y GPT: preentrenar y ajustar

2022 — ChatGPT: LLMs que siguen instrucciones

2024–26 — Razonamiento, multimodalidad y agentes



Reglas · Estadística · Redes neuronales · Preentrenamiento y LLMs

Cuatro paradigmas

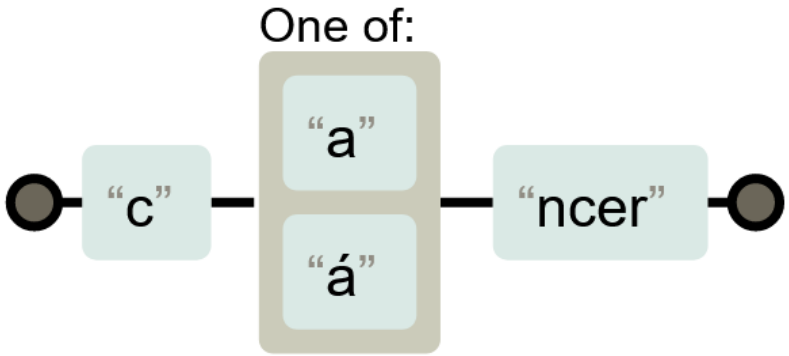
	Reglas	ML clásico	Deep learning	LLMs
Quién define las características	Un experto escribe patrones	Un ingeniero diseña features (TF-IDF, n-gramas)	La red las aprende desde texto crudo	Un modelo preentrenado ya las trae
Datos etiquetados	Ninguno	Miles	Decenas de miles	Pocos o ninguno (prompting)
Ventaja	Transparente y controlable	Barato y robusto	Alto desempeño	Versátil: una sola herramienta para muchas tareas
Límite	Frágil, no escala	Features costosas de diseñar	Datos y cómputo	Costo, alucinaciones, opacidad

Las cifras de datos etiquetados son órdenes de magnitud típicos, no reglas.

Reglas: expresiones regulares

- Paradigma clásico de programación: un desarrollador escribe reglas que imitan el comportamiento deseado.
- La herramienta más usada son las expresiones regulares: patrones para buscar en cadenas de texto.
- **Ejemplo:** ¿en cuántas fichas clínicas se menciona cáncer?
- **Límite:** cada excepción es una regla nueva (“CA de mama”, “neoplasia”…).

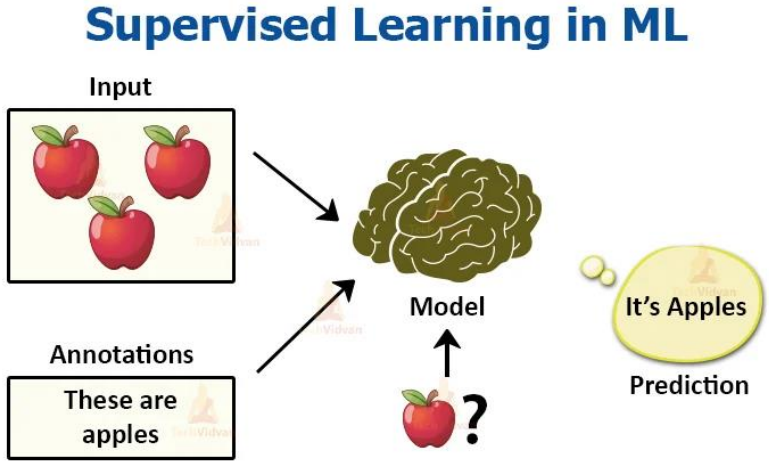
```
import re
re.findall(r"c[aá]ncer", texto, re.I)
```



c[aá]ncer acepta “cancer” y “cáncer”.

Aprendizaje automático: aprender la regla

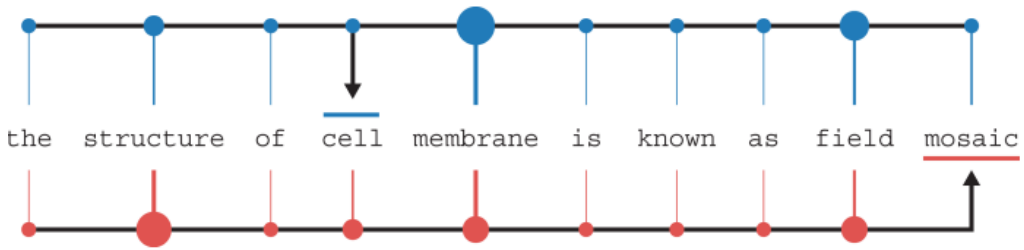
- En vez de escribir la regla, damos ejemplos etiquetados y un algoritmo aprende la función.
- **Pero:** el modelo no lee texto; necesita características numéricas.
- **Ingeniería de características:** conteos de palabras, n-gramas, largo, mayúsculas, palabras de un léxico.



El cuello de botella: diseñar buenas características requiere conocimiento del dominio e intuición

Deep learning: aprender la representación

- Las redes neuronales aprenden automáticamente las características relevantes desde el texto.
- **Embeddings** (clase 3): palabras como vectores densos.
- **Redes recurrentes** (clase 4): leen el texto en secuencia.
- **Transformers** (clase 5): la autoatención conecta palabras lejanas en paralelo.

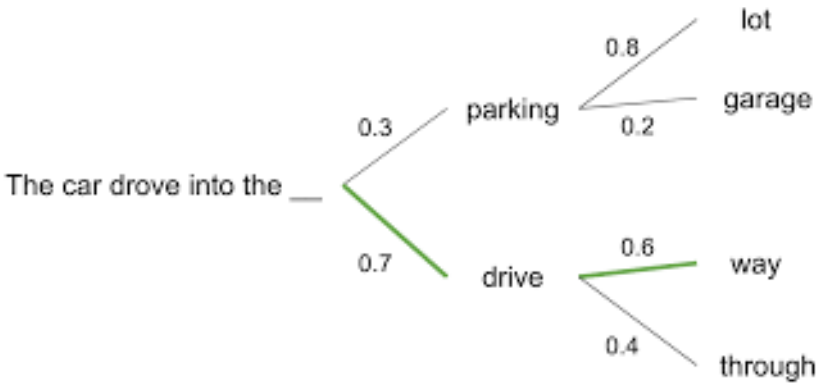


Para predecir "mosaic", el modelo se apoya en palabras lejanas como "cell" y "membrane".

Modelos de lenguaje: ¿qué palabra sigue?

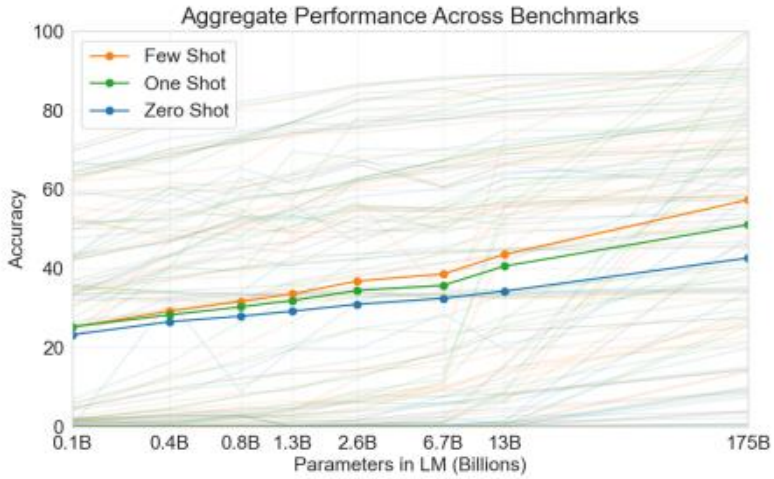
$$P(w_n \mid w_1, \ldots, w_{n-1})$$

- Un modelo de lenguaje asigna una probabilidad a cada palabra dado su contexto.
- Para generar, elige una palabra, la agrega al contexto y repite: generación autoregresiva.
- Es la misma idea del autocompletado del celular, a una escala enorme.



Predecir bien la siguiente palabra obliga a aprender gramática, hechos del mundo y algo de razonamiento

La escala cambia las reglas



- **Leyes de escala:** más parámetros, datos y cómputo dan mejor desempeño, de forma predecible.
- **Aprendizaje en contexto:** el modelo resuelve tareas nuevas con ejemplos en el prompt (zero-/few-shot).
- **Instrucciones y RLHF:** el ajuste con preferencias humanas convierte un modelo en asistente.
- **¿Habilidades emergentes?** Debate abierto: en parte dependen de la métrica (Schaeffer et al., 2023).

Fuente: Brown et al. (2020), Language Models are Few-Shot Learners.

El NLP en 2026

Razonamiento

Modelos que “piensan” antes de responder, gastando más cómputo en inferencia.

Multimodalidad

Texto, imagen, audio y video en un mismo modelo.

Agentes

Usan herramientas, buscan, ejecutan código y encadenan pasos.

RAG

Responder con documentos propios para reducir alucinaciones.

Modelos abiertos

Llama, Qwen, Mistral, DeepSeek o Gemma: se ajustan y despliegan localmente.

Eficiencia

Cuantización y LoRA para usar y ajustar modelos con poco hardware.

Todo esto se apoya en los fundamentos del curso: tokens, embeddings, atención y preentrenamiento.

¿Sigue importando el NLP clásico?

Conviene un LLM cuando…

- La tarea es abierta o hay que generar texto
- Hay pocas o ninguna etiqueta
- Se necesita un prototipo rápido

Conviene un método clásico cuando…

- La tarea es acotada y bien definida
- Hay millones de documentos y el costo importa
- Se necesita explicar y auditar la decisión
- Los datos sensibles no pueden salir de la institución

Regla práctica: parte con un baseline simple, mide, y escala solo si la mejora lo justifica

Tareas del NLP

Qué problemas resolvemos con texto y voz

Un mapa de tareas

Comprensión

- Clasificación
- Sentimiento
- Entidades (NER)
- Extracción de información
- Preguntas y respuestas

Generación

- Resumen
- Traducción
- Diálogo
- Redacción y código

Voz

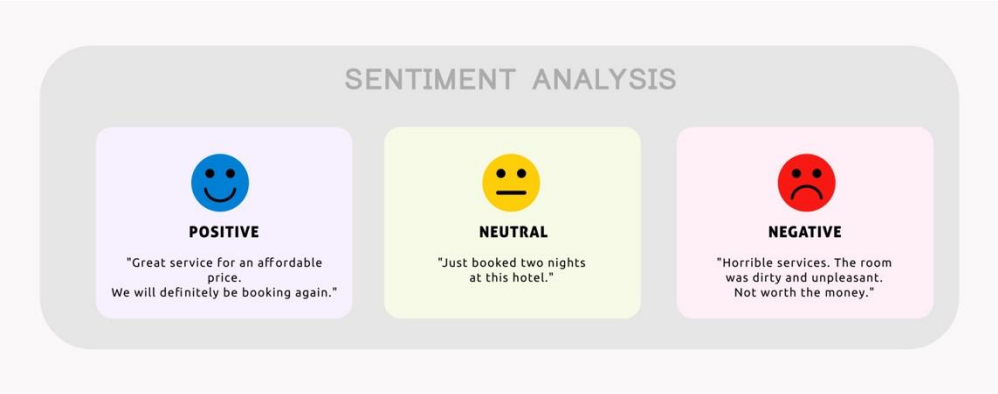
- Reconocimiento del habla (ASR)
- Síntesis de voz (TTS)

Multimodal

- Texto → imagen
- Descripción de imágenes
- Documentos escaneados

Clasificación de texto

Asignar una o más categorías a un texto libre. Es la tarea más común en la industria.



Análisis de sentimiento: positivo, neutro o negativo.

- Spam / no spam
- Tema de una noticia
- Sentimiento de una reseña
- Urgencia de un reclamo
- Código CIE-10 de un diagnóstico

Reconocimiento de entidades nombradas

Localizar entidades en un texto y clasificarlas en categorías: persona, organización, lugar, fecha… o las de un dominio.



Entidades en una ficha clínica en español: edad, fecha, ocupación, institución.

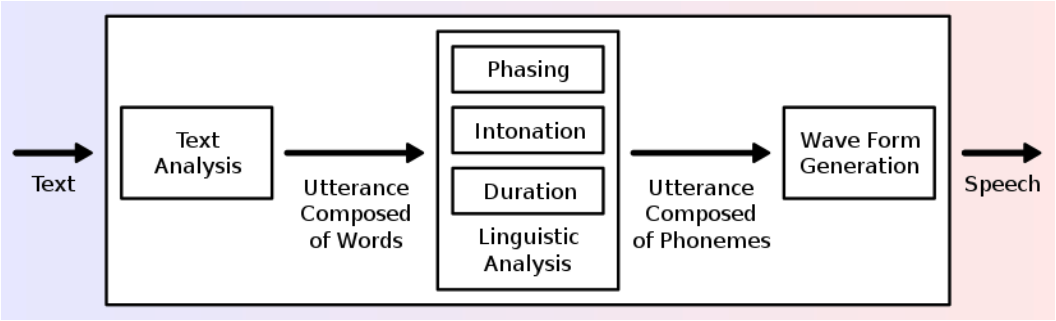
Voz: reconocer y sintetizar

Reconocimiento (ASR)

Voz → texto. Procesa la señal de audio y la decodifica como una secuencia de palabras.

Síntesis (TTS)

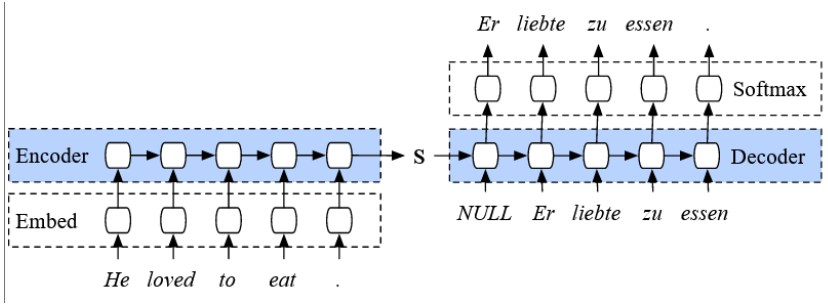
Texto → voz. Reconstruye la señal de audio que corresponde a un texto.



Pipeline clásico de síntesis de voz. Hoy ambas tareas se resuelven de extremo a extremo con redes neuronales.

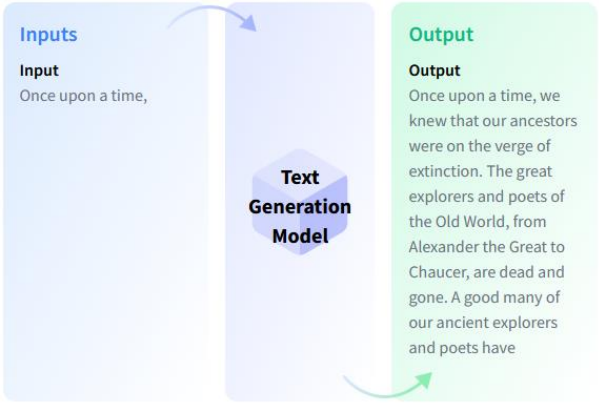
Traducción automática

- Convierte una secuencia de palabras de un idioma a otro.
- **Secuencia a secuencia:** un codificador representa el significado y un decodificador lo reconstruye en otro idioma.
- El Transformer nació en 2017 justamente para traducir.
- Hoy los LLMs traducen entre cientos de idiomas, pero rinden peor en lenguas con pocos datos, como el mapudungun.



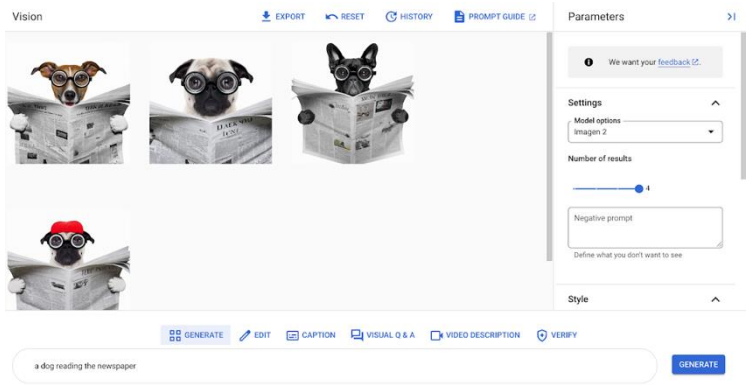
Codificador–decodificador: "He loved to eat" → "Er liebte zu essen".

Generación de texto e imágenes



Texto

El modelo completa la secuencia palabra a palabra a partir de un inicio (prompt).



Imágenes

Un modelo de lenguaje codifica la descripción y un modelo generativo produce la imagen.

Ética y riesgos

Sesgos

Los modelos aprenden estereotipos de los datos: “el doctor”, “la enfermera”.

Alucinaciones

Respuestas fluidas pero falsas: datos y citas inventadas.

Desinformación

Texto, voz y video sintéticos a escala: bots y deepfakes.

Privacidad

Datos personales en el entrenamiento y en los prompts. En Chile, Ley 21.719.

Trabajo

Automatización de redacción, traducción y atención; nuevas habilidades.

Costo ambiental

Energía y agua para entrenar y servir modelos grandes.

Volveremos a estos temas en las clases de embeddings (sesgos) y de alineamiento de LLMs.

Contenido del curso

1. **Introducción y preprocesamiento**
   Tokenización, normalización, exploración
2. **Semántica vectorial**
   Bag of Words, TF-IDF
3. **Word embeddings**
   word2vec, GloVe, fastText
4. **Deep learning y redes recurrentes**
   RNN, LSTM, GRU
5. **Transformers**
   Autoatención, BERT, GPT
6. **Grandes modelos de lenguaje**
   Prompting, few-shot, habilidades emergentes
7. **Cuantización y fine-tuning eficiente**
   LoRA, QLoRA
8. **Alineamiento de LLMs**
   RLHF, DPO, GRPO

Dinámica y evaluación

Cada clase tiene tres partes

Cátedra
Conceptos y modelos

Tutorial
Código guiado en notebooks

Laboratorio
Ejercicio práctico en clase

Evaluación

3 tareas prácticas en grupo

La evaluación del curso consiste en dos tareas prácticas grupales: aplicar las técnicas vistas a un problema con datos reales.

Ahora en Python

1.1

Preprocesamiento

Normalización · tokenización con regex · BPE y WordPiece · stemming y lematización

1.2

Exploración

Diversidad léxica · ley de Heaps · frecuencias y nubes de palabras · TF-IDF · concordancias y bigramas