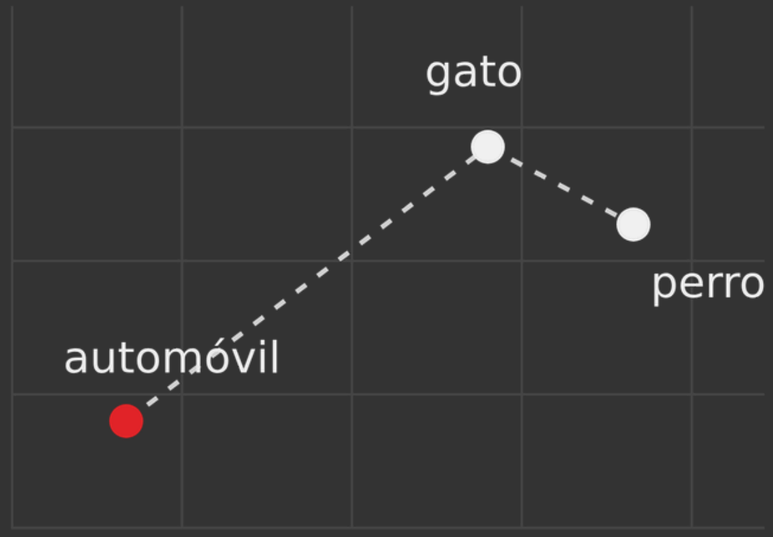
dcc
CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

Clase 2
Semántica vectorial

[CC66Q] Procesamiento de Lenguaje Natural



Andrés Abeliuk · Fabrizzio Pezzolla

Diplomado en Inteligencia Artificial

¿Por qué nos interesan los vectores?

Porque nos permiten usar álgebra lineal

Queremos obtener una representación vectorial del lenguaje

Clase de hoy

- Semántica distribucional
  - Valor lingüístico
  - Parecidos de familia
  - Hipótesis distribucional
- Juego
- Representación vectorial de documentos
  - BoW
  - TF-IDF
  - LSA
- Break
- Tutorial

Parte 1
Semántica distribucional

Buscamos llevar el significado a un espacio vectorial.

Para eso no nos importa tanto la representación del significado de un término aislado, sino cómo se relacionan los términos entre sí dentro de ese espacio.

Nombres como significado

«Cuando ellos (los mayores) nombraban alguna cosa y consecuentemente con esa apelación se movían hacia algo, lo veía y comprendía que con los sonidos que pronunciaban llamaban ellos a aquella cosa cuando pretendían señalarla. […]»

Agustín (c. 400), en Wittgenstein (1953)

«[…] Las palabras del lenguaje nombran objetos — las oraciones son combinaciones de esas denominaciones.»

Wittgenstein (1953)



San Agustín

Obispo de Hipona,
354 – 430.

Philippe de Champaigne, c. 1645–1650. Wikimedia Commons, dominio público.

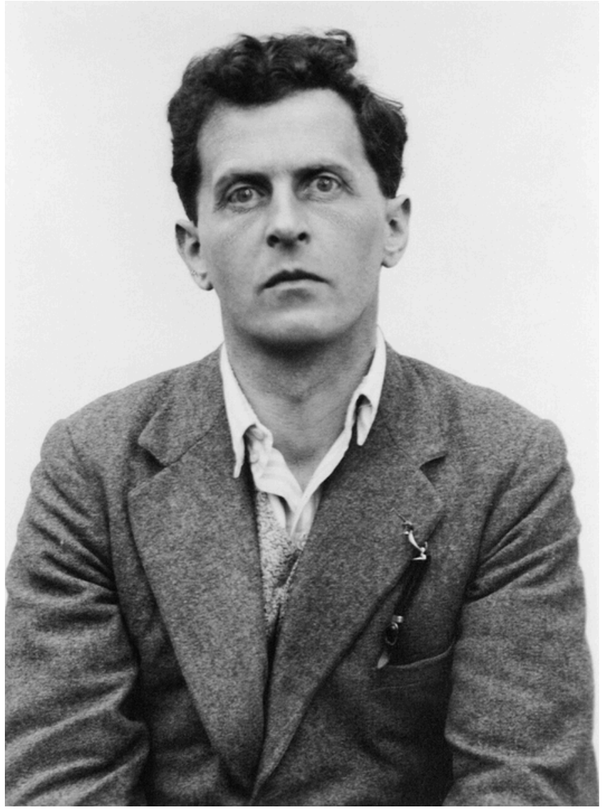
Uso como significado

¿Cómo se enseña el significado?

«[…] el instructor señale los objetos, dirija la atención del niño hacia ellos y pronuncie a la vez una palabra; por ejemplo, la palabra "losa" mientras muestra esa forma.»

«"Al conectar la barra con la palanca puse el freno."— Sí, dado todo el resto del mecanismo. […]»

Wittgenstein (1953)



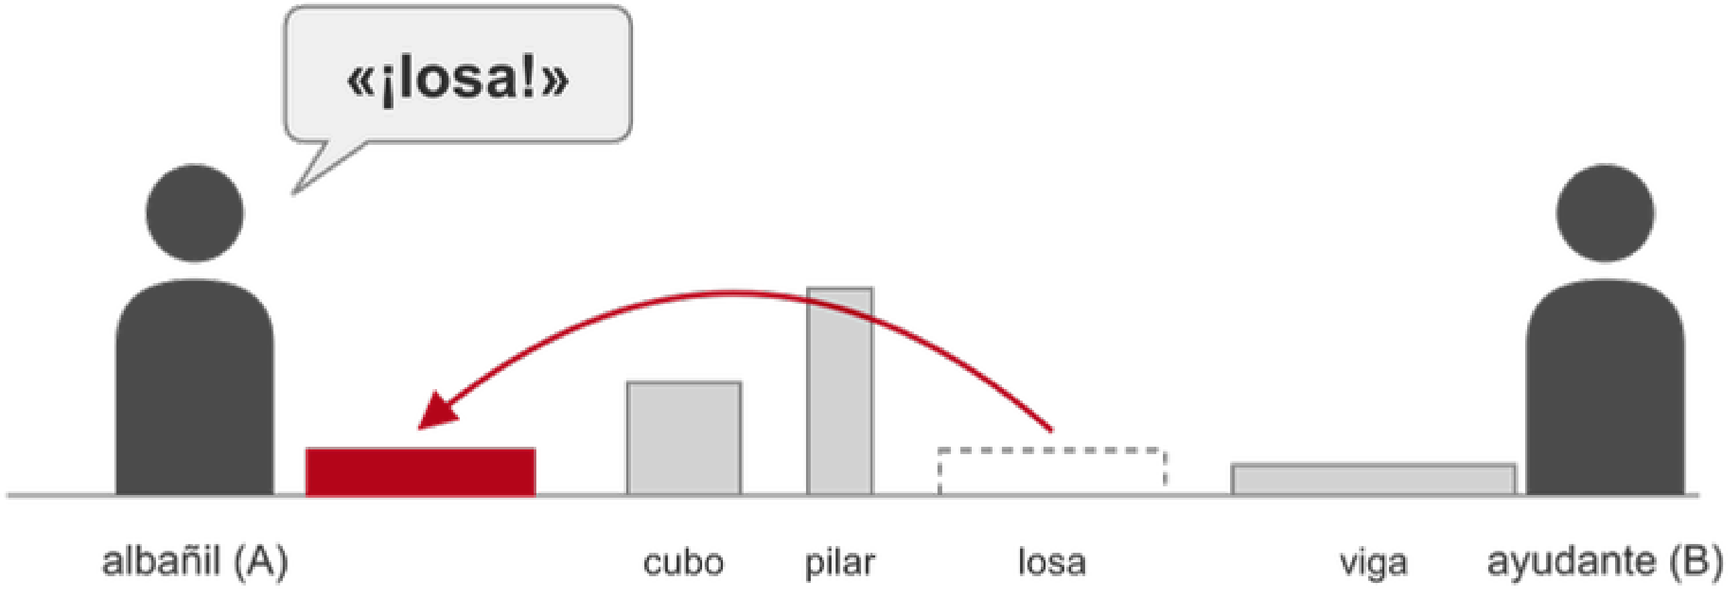
Ludwig Wittgenstein

Filósofo austríaco-británico,
1889 – 1951.

Moritz Nähr, 1928–1929. Wikimedia Commons, dominio público.

Uso como significado

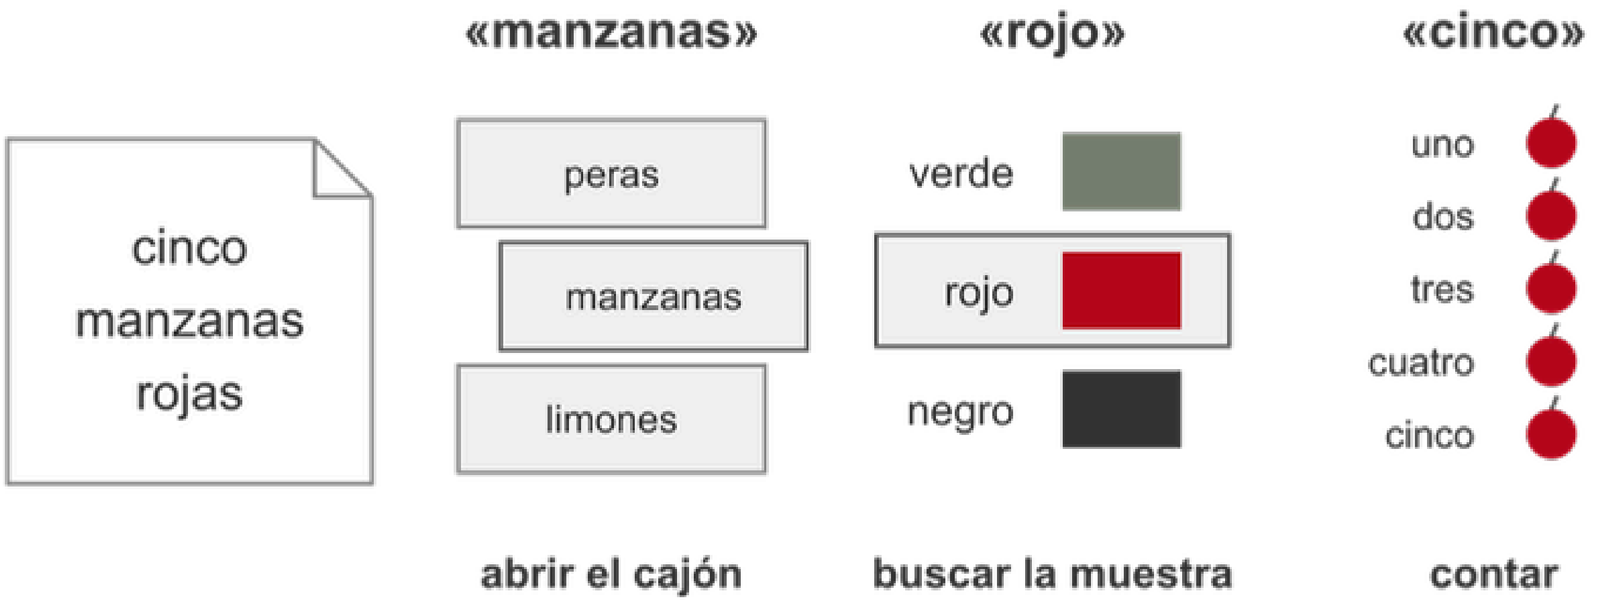
«Imaginémonos un lenguaje para el que vale una descripción como la que ha dado Agustín.»



«A las grita — B le lleva la piedra que ha aprendido a llevar a ese grito.»

Wittgenstein (1953)

Uso como significado



«¿Pero cuál es el significado de la palabra "cinco"? — No se habla aquí en absoluto de tal cosa; sólo de cómo se usa la palabra "cinco".»

Wittgenstein (1953)

Uso como significado

«Llamaré también "juego de lenguaje" al todo formado por el lenguaje y las acciones con las que está entretejido.»

Wittgenstein (1953)

«Para una gran clase de casos de utilización de la palabra "significado" — aunque no para todos los casos de su utilización — puede explicarse esta palabra así: El significado de una palabra es su uso en el lenguaje.»

Wittgenstein (1953)

Diferencias como significado

«Para ciertas personas, la lengua, reducida a su principio esencial, es una nomenclatura, es decir, una lista de términos que corresponden a otras tantas cosas. […] Esta concepción es criticable en muchos aspectos.»

Saussure (1916)



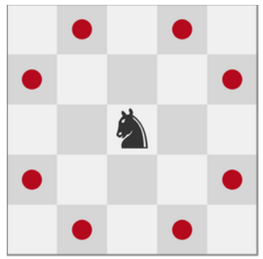
Ferdinand de Saussure

Lingüista suizo,
1857 – 1913.

F. Jullien, antes de 1913. Wikimedia Commons, dominio público.

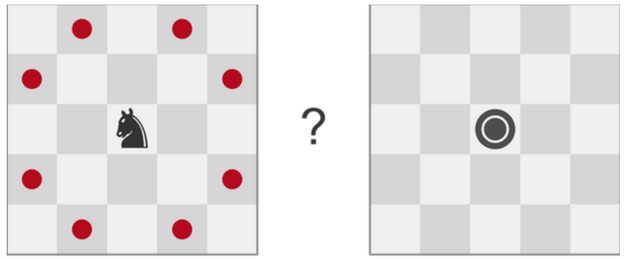
Diferencias como significado

«Tomemos un caballo: ¿es por sí solo un elemento del juego?»



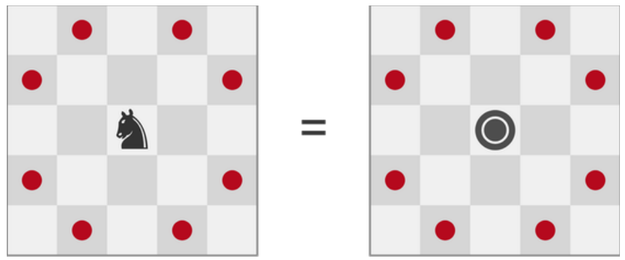
caballo

«Supongamos que durante una partida esta pieza se destruye o se pierde: ¿se la puede reemplazar por otra equivalente?»



caballo ? tapa de botella

«Ciertamente: no solo otro caballo, sino incluso una figura desprovista de todo parecido con este será declarada idéntica, con tal que se le atribuya el mismo valor.»



caballo = tapa de botella

Saussure (1916)



Ferdinand de Saussure

Lingüista suizo,
1857 – 1913.

F. Jullien, antes de 1913. Wikimedia Commons, dominio público.

Diferencias como significado

	el animal	la carne servida en la mesa
francés	*mouton*	
inglés	*sheep*	*mutton*

«El francés mouton puede tener la misma significación que el inglés sheep, pero no el mismo valor […].»

Saussure (1916)



Ferdinand de Saussure

Lingüista suizo,
1857 – 1913.

F. Jullien, antes de 1913. Wikimedia Commons, dominio público.

Diferencias como significado

- La lengua no es una nomenclatura: no es una lista de nombres para cosas.
- El signo es arbitrario: nada en «perro» se parece a un perro.
- El valor de una palabra depende de sus diferencias con las demás.



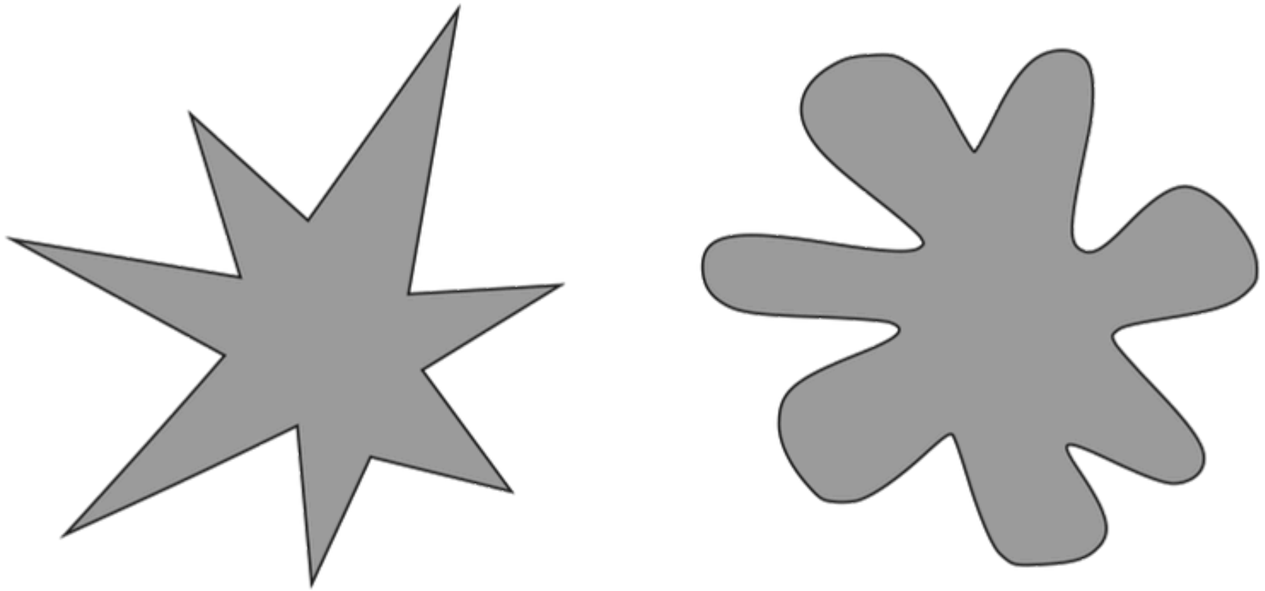
Ferdinand de Saussure

Lingüista suizo,
1857 – 1913.

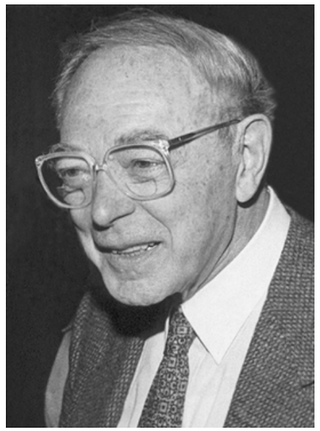
F. Jullien, antes de 1913. Wikimedia Commons, dominio público.

Saussure (1916)

TANGENTE



Hipótesis distribucional



Zellig S. Harris

Lingüista estadounidense,
1909 – 1992.

- La distribución de una palabra es la suma de todos sus entornos.
- La diferencia de significado corresponde aproximadamente a la diferencia de entornos.



John Rupert Firth

Lingüista británico,
1890 – 1960.

- Cita a Wittgenstein: el significado de una palabra está en su uso.
- Una palabra se conoce por la compañía que mantiene.

Harris (1954) · Firth (1957)

Hipótesis distribucional



John Rupert Firth

Lingüista británico,
1890 – 1960.

«Como dice Wittgenstein, "el significado de las palabras reside en su uso". […]

¡Conocerás una palabra por la compañía que mantiene!»

Firth (1957)

Hipótesis distribucional

«Las palabras que aparecen en contextos similares tienden a tener significados similares.»

una palabra desconocida	palabras conocidas
El **ongchoi** es **delicioso** salteado con **ajo**.	… **espinaca** salteada con **ajo** sobre **arroz** …
El **ongchoi** es excelente sobre **arroz**.	… los tallos y las hojas de **acelga** son **deliciosos** …
… hojas de **ongchoi** con salsas **saladas** …	… **berza** y otras verduras de hoja **saladas**

¿Qué es el ongchoi?

Jurafsky y Martin (2026)

Matriz documento-término

La entrada (i, j) cuenta cuántas veces aparece el término j en el documento i.

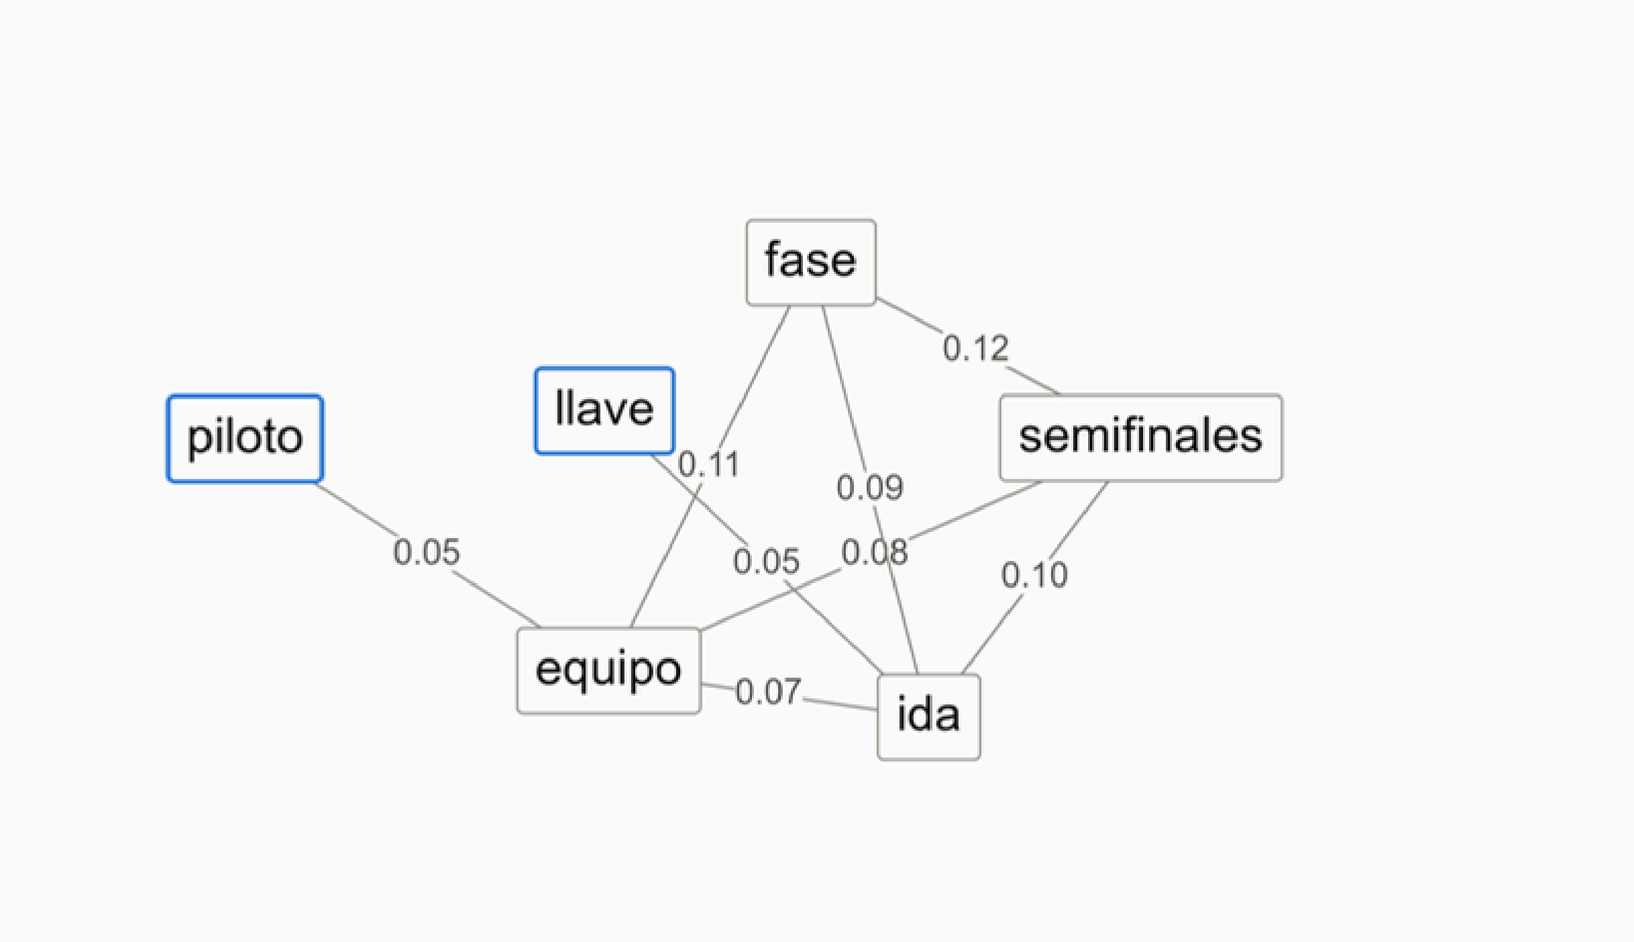
	t_1	t_2	t_3	t_4	t_5	⋯	t_n
d_1	1	1	0	1	1	⋯	0
d_2	1	1	0	0	0	⋯	0
d_3	0	0	0	0	2	⋯	1
d_4	0	0	1	1	1	⋯	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
d_m	0	2	1	0	0	⋯	1

fila: el documento d_1

columna: el término t_1

Ahora que tenemos una representación vectorial,
¿qué podemos hacer?

Conecta las palabras



Parte 2
Similitud entre documentos

Órbita

(2025) - 1 h 52 min

Una astronauta viaja al espacio durante un año para estudiar la química de una estrella cercana. A esa distancia pierde el contacto con la base, y la atracción de la estrella empieza a sacar su cápsula de órbita. Sin señal, debe buscar la forma de volver.

¿Cuál se parece más a Órbita?

Órbita

(2025) - 1 h 52 min

Una astronauta viaja al espacio durante un año para estudiar la química de una estrella cercana. A esa distancia pierde el contacto con la base, y la atracción de la estrella empieza a sacar su cápsula de órbita. Sin señal, debe buscar la forma de volver.

Deriva

(2025) - 1 h 34 min

Un astronauta analiza la química de un cometa desde una cápsula en órbita. Cuando una tormenta daña la antena, la señal se corta y el módulo queda a la deriva en el espacio.

Masa madre

(2023) - 1 h 48 min

Dos hermanas heredan la panadería de su madre. Entre deudas y recetas antiguas, intentan salvarla y descubren secretos que cambian lo que creían saber de ella.

Bolsa de palabras (BoW)

	astronauta	cápsula	espacio	química	señal	órbita	estrella	panadería	…
Órbita	1	1	1	1	1	1	2	0	…
Deriva	1	1	1	1	1	1	0	0	…
Masa madre	0	0	0	0	0	0	0	1	…

¿Cuánto se parecen dos sinopsis?

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|}$$

Órbita · Deriva = 6 (seis palabras en común, cada una 1 × 1)

‖Órbita‖ = √24 ≈ 4,90 ‖Deriva‖ = √15 ≈ 3,87

¿Cuánto se parecen dos sinopsis?

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|}$$

Órbita · Deriva = 6 (seis palabras en común, cada una 1 × 1)

‖Órbita‖ = √24 ≈ 4,90 ‖Deriva‖ = √15 ≈ 3,87

$$\cos(\text{Órbita}, \text{Deriva}) = \frac{6}{\sqrt{24}\sqrt{15}} \approx 0{,}32$$

Deriva: 0,32 Masa madre: 0

¿Cuál se parece más a Órbita: Deriva o La casa del sur?

Órbita

(2025) - 1 h 52 min

Una astronauta viaja al espacio durante un año para estudiar la química de una estrella cercana. A esa distancia pierde el contacto con la base, y la atracción de la estrella empieza a sacar su cápsula de órbita. Sin señal, debe buscar la forma de volver.

Deriva

(2025) - 1 h 34 min

Un astronauta analiza la química de un cometa desde una cápsula en órbita. Cuando una tormenta daña la antena, la señal se corta y el módulo queda a la deriva en el espacio.

La casa del sur

(2022) - 1 h 52 min

Un año después de la muerte de su padre, Marta viaja al pueblo donde creció para vender la casa. Pierde el contacto con la ciudad y empieza a dudar. Cuando encuentra una carta de su madre, debe buscar la forma de volver.

Con BoW gana La casa del sur

Órbita

Una astronauta viaja al espacio durante un año para estudiar la química de una estrella cercana. A esa distancia pierde el contacto con la base, y la atracción de la estrella empieza a sacar su cápsula de órbita. Sin señal, debe buscar la forma de volver.

Deriva

6 palabras en común

astronauta
cápsula
espacio
química
señal
órbita

BoW: 0,32

La casa del sur

8 palabras en común

año
buscar
contacto
empieza
forma
pierde
viaja
volver

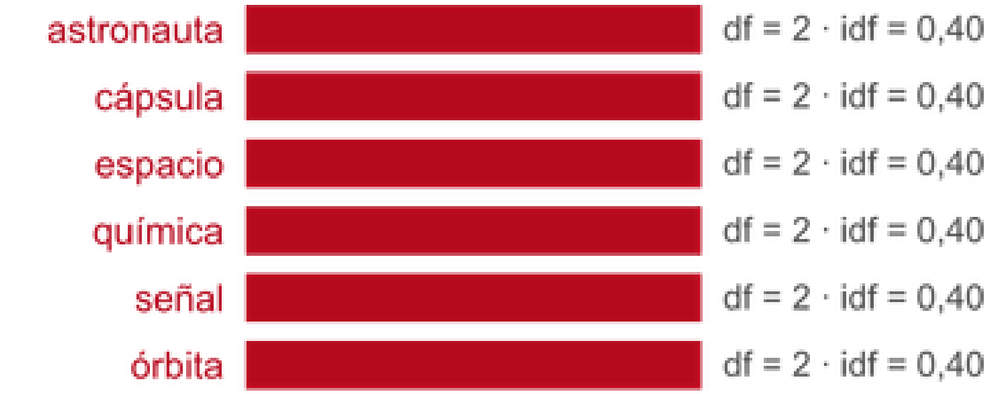
BoW: 0,38

TF-IDF

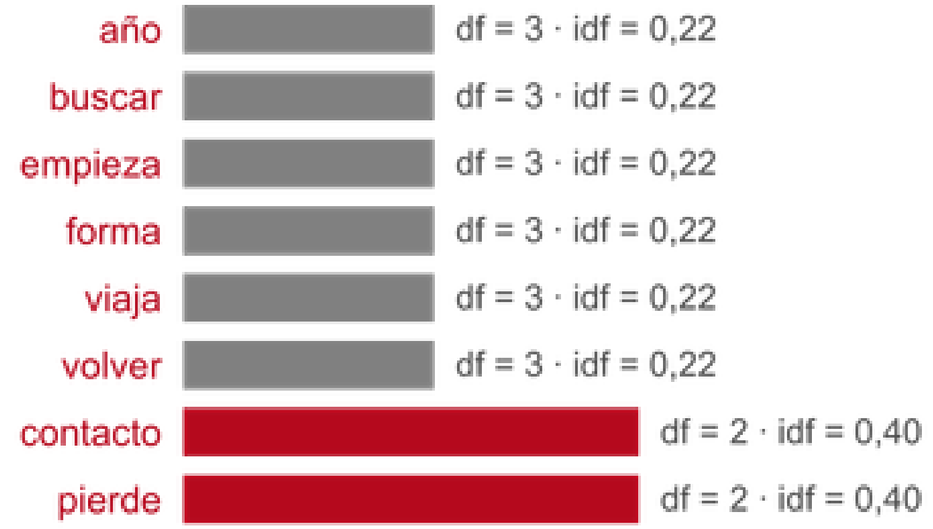
$$\text{tf-idf}(t, d) = \text{tf}(t, d) \cdot \log_{10} \frac{N}{\text{df}(t)}$$

tf: veces que aparece la palabra t en d · df: en cuántas sinopsis aparece t · N = 5 sinopsis

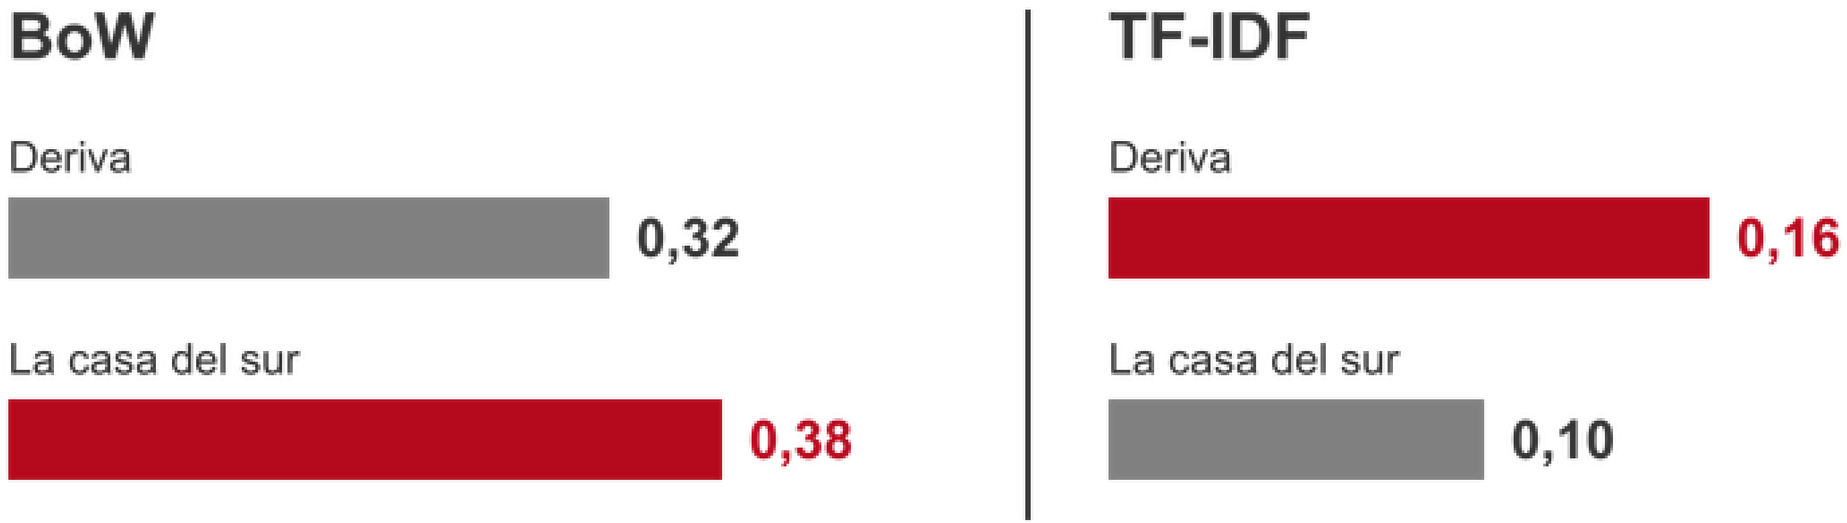
Las que comparte Deriva



Las que comparte La casa del sur



¿Cuál se parece más a Órbita?



¿Y Destino Kepler?

Órbita

(2025) - 1 h 52 min

Una astronauta viaja al espacio durante un año para estudiar la química de una estrella cercana. A esa distancia pierde el contacto con la base, y la atracción de la estrella empieza a sacar su cápsula de órbita. Sin señal, debe buscar la forma de volver.

Destino Kepler

(2023) - 2 h 08 min

Tras décadas a bordo de una nave que viaja rumbo a otro planeta, la tripulación despierta del sueño criogénico y descubre que el piloto automático cambió el destino. Cada año de desvío cuenta, y empieza una carrera para buscar la forma de volver a la ruta.

Solo comparten palabras que aparecen en todas partes

Órbita	Destino Kepler
astronauta	tripulación
cápsula	nave
órbita	planeta
estrella	criogénico
espacio	piloto

En común: año · buscar · empieza · forma · viaja · volver

Solo comparten palabras que aparecen en todas partes

Órbita	Destino Kepler
astronauta	tripulación
cápsula	nave
órbita	planeta
estrella	criogénico
espacio	piloto

En común: año · buscar · empieza · forma · viaja · volver

BoW: 0,26 **TF-IDF: 0,04**

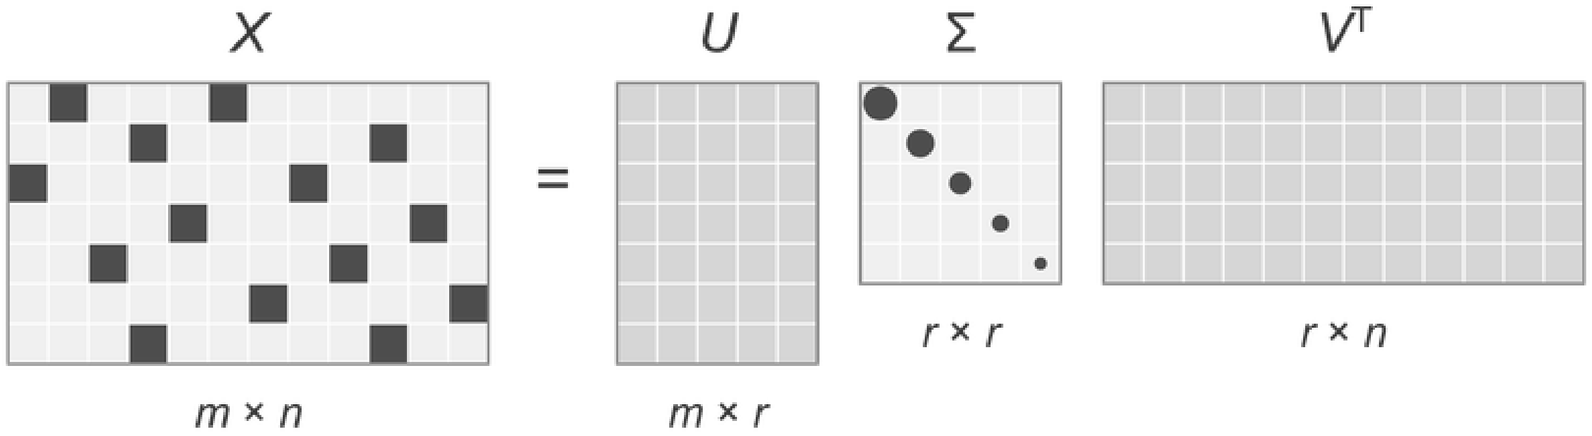
¿Por qué Destino Kepler queda lejos?

«[…] cada tipo de palabra se trata como independiente de cualquier otro.»

Deerwester et al. (1990)

Descomposición en valores singulares

$$X = U \Sigma V^{\mathsf{T}}$$

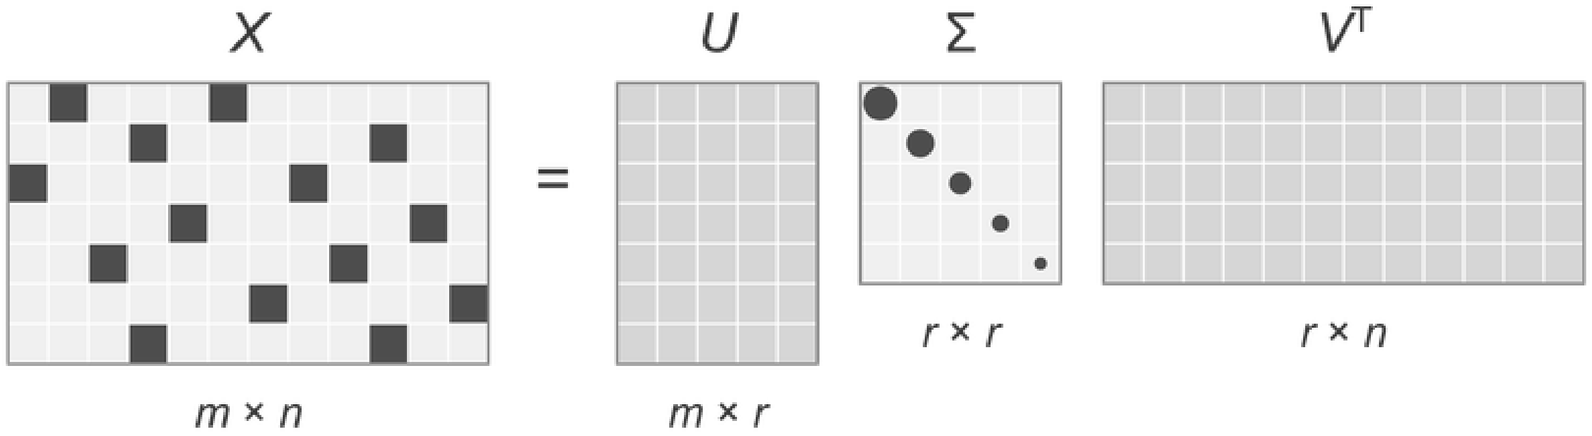


«Cualquier matriz rectangular […] puede descomponerse en el producto de otras tres matrices […].»

Deerwester et al. (1990)

Descomposición en valores singulares

$$X = U \Sigma V^{\mathsf{T}}$$



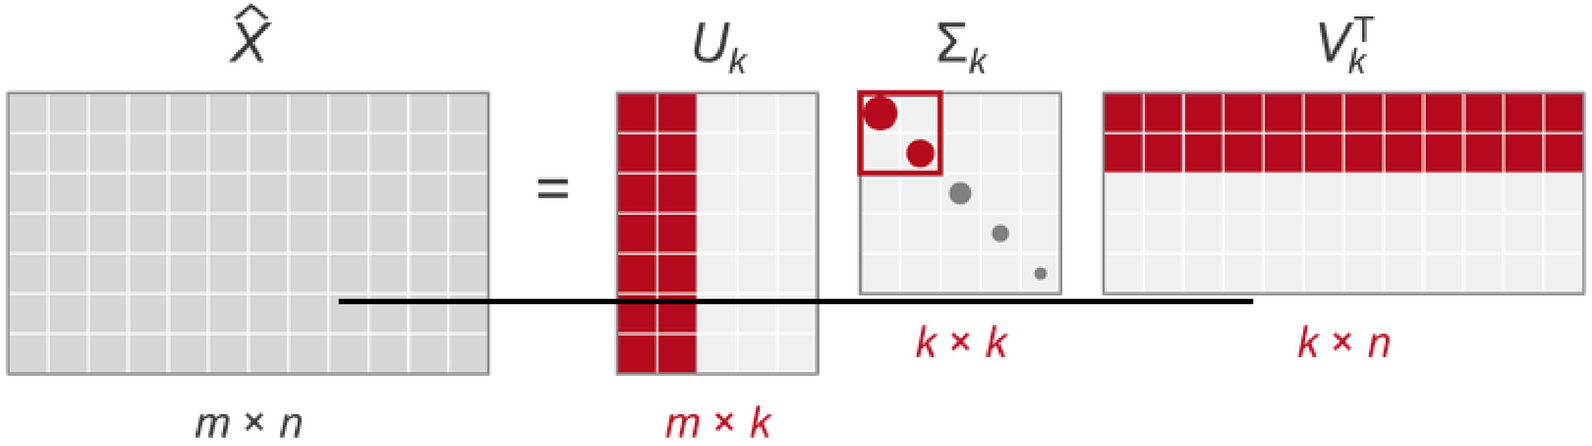
$$U^{\mathsf{T}}U = I \qquad V^{\mathsf{T}}V = I \qquad \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

«Cualquier matriz rectangular […] puede descomponerse en el producto de otras tres matrices […].»

Deerwester et al. (1990)

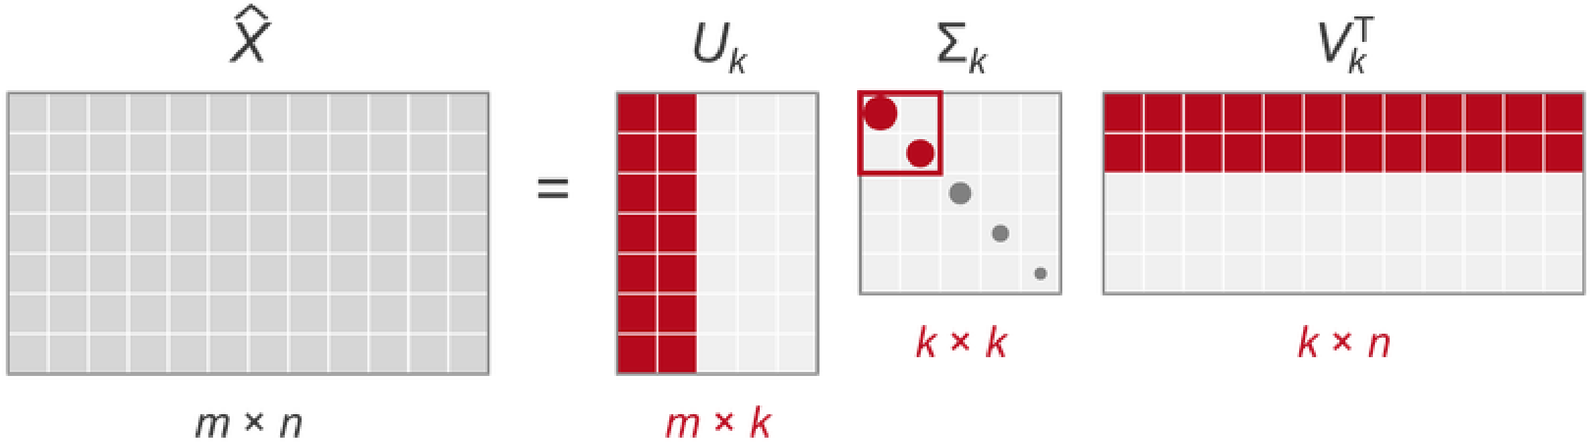
SVD truncada

$$X \approx \hat{X} = U_k \, \Sigma_k \, V_k^{\mathsf{T}}$$



SVD truncada

$$X \approx \hat{X} = U_k \, \Sigma_k \, V_k^{\mathsf{T}}$$



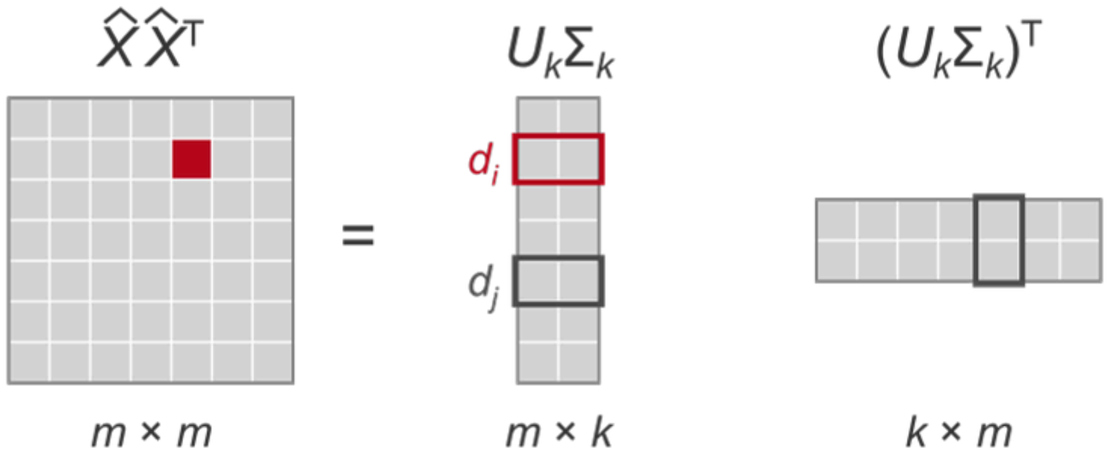
$$\hat{X} = \underset{\text{rango}(Y) \leq k}{\arg\min} \sum_{i,j} (x_{ij} - y_{ij})^2$$

«Se puede demostrar que la nueva matriz X̂ es la matriz de rango k más cercana a X en el sentido de mínimos cuadrados.»

Deerwester et al. (1990)

¿Dónde queda cada documento?

$$\hat{X}\hat{X}^{\mathsf{T}} = U_k \Sigma_k^2 U_k^{\mathsf{T}}$$



$$(\hat{X}\hat{X}^{\mathsf{T}})_{ij} = (U_k\Sigma_k)_i \cdot (U_k\Sigma_k)_j$$

Órbita y Destino Kepler

«[…] en virtud de la reducción de dimensión, es posible que documentos con perfiles de uso de términos algo distintos se asignen al mismo vector de valores de factores.»

Deerwester et al. (1990)

Similitud con Órbita

	BoW	TF-IDF	LSA
Deriva	0,32	0,16	**alta**
Masa madre	0	0	**baja**
La casa del sur	0,38	0,10	**media**
Destino Kepler	0,26	0,04	**alta**

Referencias

Agustín de Hipona (c. 400). Confesiones, libro I, cap. 8.

Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K. y Harshman, R. (1990). Indexing by latent semantic analysis. Journal of the American Society for Information Science, 41(6), 391–407.

Eckart, C. y Young, G. (1936). The approximation of one matrix by another of lower rank. Psychometrika, 1(3), 211–218.

Firth, J. R. (1957). A synopsis of linguistic theory, 1930–1955. En Studies in Linguistic Analysis (pp. 1–32). Oxford: Blackwell.

Harris, Z. S. (1954). Distributional structure. Word, 10(2–3), 146–162.

Jurafsky, D. y Martin, J. H. (2026). Speech and Language Processing (3.ª ed., borrador), cap. 5: Embeddings.

Köhler, W. (1929). Gestalt Psychology. Nueva York: Liveright.

Ramachandran, V. S. y Hubbard, E. M. (2001). Synaesthesia: A window into perception, thought and language. Journal of Consciousness Studies, 8(12), 3–34.

Saussure, F. de (1916). Cours de linguistique générale. Ed. C. Bally y A. Sechehaye. París: Payot.

Wittgenstein, L. (1953). Investigaciones filosóficas. Trad. A. García Suárez y U. Moulines. Barcelona: Crítica; México: UNAM, 1988.