Clase 4
Redes neuronales recurrentes

[CC66Q] Procesamiento de Lenguaje Natural

Andrés Abeliuk y Fabrizzio Pezzolla

Diplomado en Inteligencia Artificial

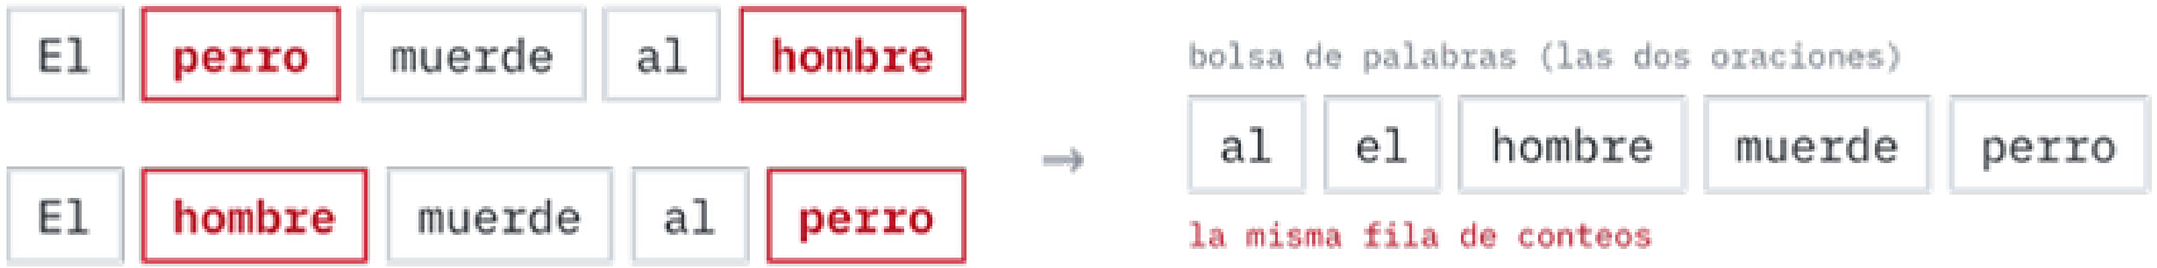


¿Qué vimos en las clases anteriores?

Clase 2: un documento es una fila de la matriz documento-término,
con el número de veces que aparece cada palabra (bolsa de palabras)
o esos conteos ponderados (TF-IDF).
Clase 3: una palabra es un vector denso, aprendido de sus contextos.

Si cambiamos el orden de las palabras de un documento, ¿cambia su fila?

El orden de las palabras



¿Qué tendría que guardar un modelo para distinguirlas?

Pregunta

¿Cómo representamos el orden de las palabras?

1. ¿Cómo guardamos el orden de las palabras?
2. ¿Cómo recordamos una palabra lejana?
3. ¿Cómo producimos una salida de otro largo?
4. ¿Qué pasa cuando todo tiene que caber en un solo vector?

El orden de las palabras

El significado de una oración depende de sus palabras y de cómo se combinan.

En español el orden es más libre que en inglés, pero no del todo:

Muerde el perro al hombre.

Al hombre lo muerde el perro.

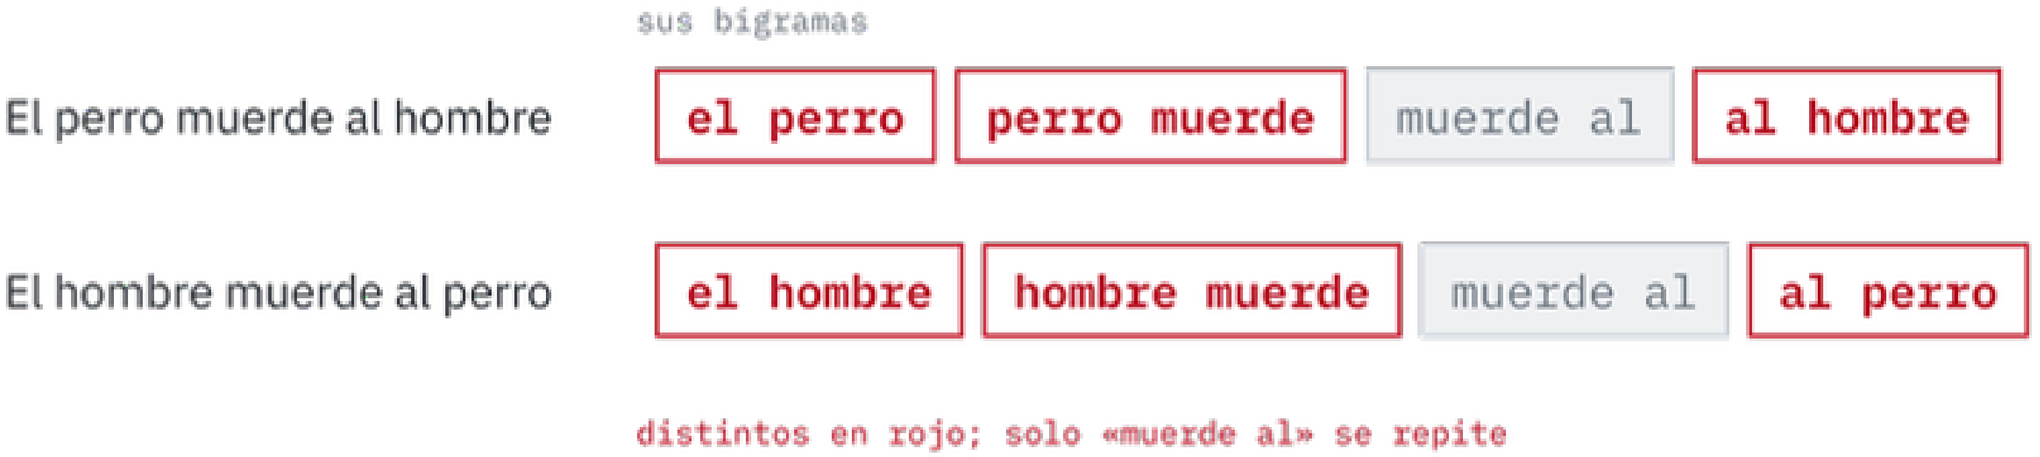
Pregunta 1 de 4

¿Cómo guardamos el orden de las palabras?



Cadenas de Markov y n-gramas

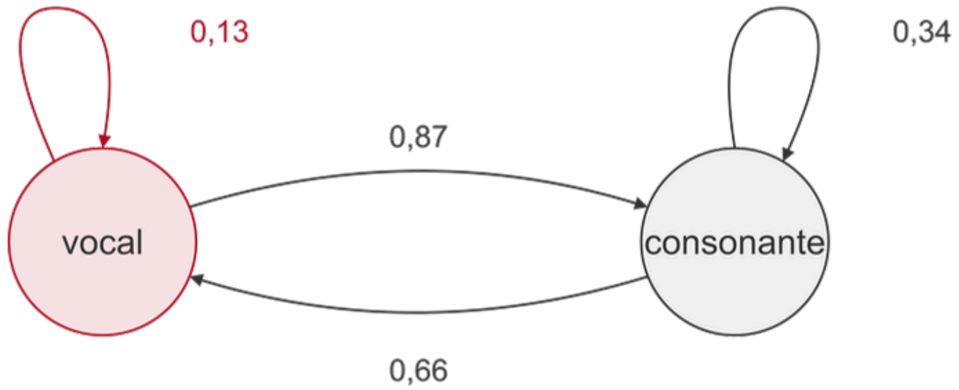
Un n-grama es una secuencia de n palabras seguidas: unigramas (n = 1), bigramas (n = 2), trigramas (n = 3). Los unigramas de las dos oraciones son los mismos.



Cadenas de Markov y n-gramas

La ley de los grandes números: al repetir muchas veces un experimento, la frecuencia de un resultado se acerca a su probabilidad. Estaba demostrada para sucesos independientes, como los lanzamientos de una moneda.

El problema de Andréi Markov, matemático ruso: ¿vale también cuando cada suceso depende del anterior?



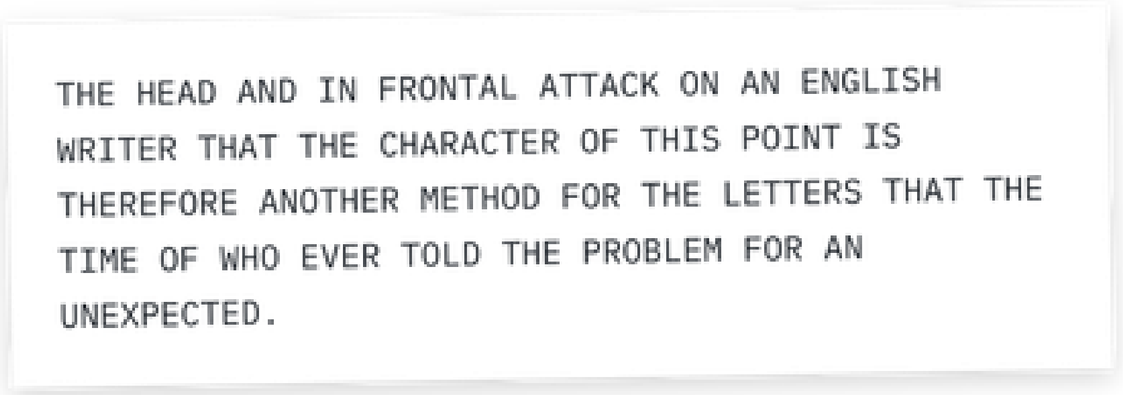
probabilidad de la letra siguiente según la anterior, en 20.000 letras de Eugenio Oneguin

En un texto, cada letra depende de la anterior. Markov clasificó en vocales y consonantes las primeras 20.000 letras de Eugenio Oneguin, la novela en verso de Pushkin.

Cadenas de Markov y n-gramas

Claude Shannon, ingeniero de los Laboratorios Bell, creó la teoría de la información. Para medir cuánta información lleva un mensaje, necesitaba un modelo estadístico de la fuente que lo produce.

> «6. Aproximación de segundo orden por palabras. Las probabilidades de transición entre palabras son correctas, pero no se incluye más estructura.»
>
> Shannon (1948), §3



↑ hoy lo llamamos un modelo de bigramas

Shannon generó este texto con un libro: buscaba la última palabra escrita y copiaba la que venía después.

Ese modelo estadístico se llama hoy modelo de lenguaje: da la probabilidad de la palabra siguiente, dadas las anteriores.

Cadenas de Markov y n-gramas

Un modelo de n-gramas es una tabla de conteos. En 6,6 millones de palabras de argumentos de películas:

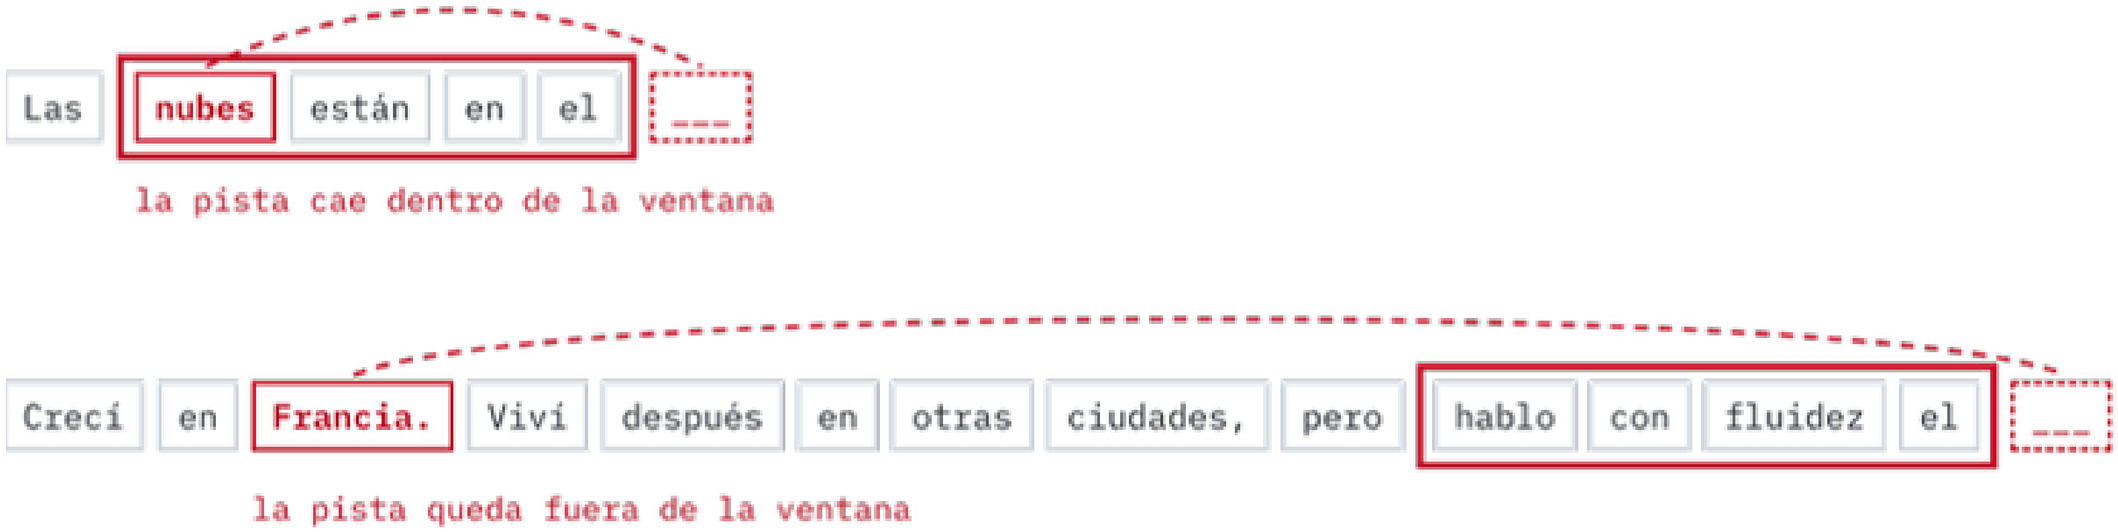
muerde al	3
el perro	254
perro muerde	0
bigramas vistos una vez	68 %



Más texto reduce la escasez: en 2006, Google publicó conteos de n-gramas de un billón de palabras de la web.

Si un n-grama no aparece, el backoff usa uno más corto: si falta «perro muerde», usa «muerde».

Cadenas de Markov y n-gramas



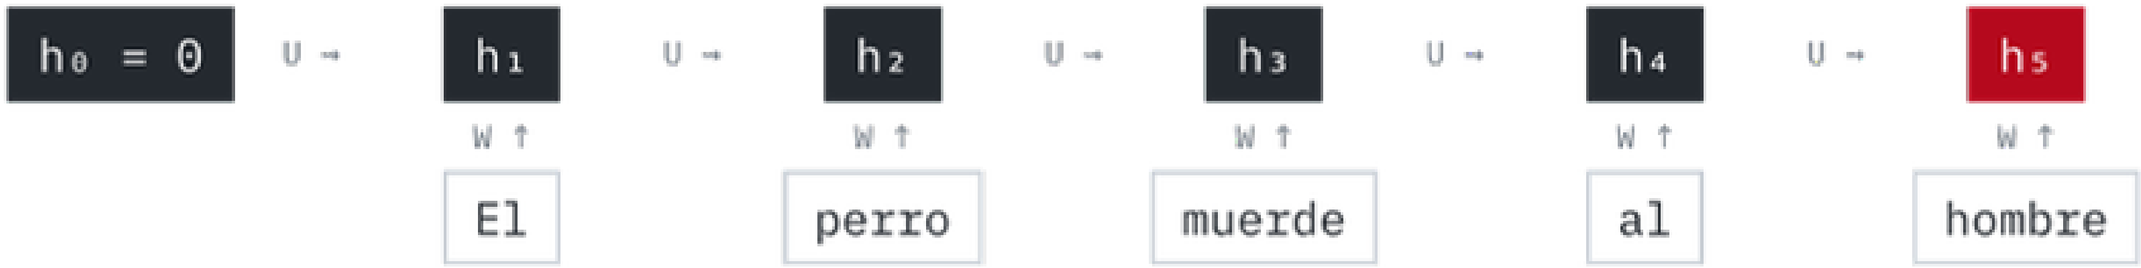
¿Qué palabra falta en cada oración?

Las redes neuronales de la época también leían el texto con una ventana fija.

Olah (2015), ejemplos adaptados

La red recurrente simple

Jeffrey Elman, científico cognitivo de la Universidad de California en San Diego, buscaba una red que leyera secuencias de cualquier largo, sin ventana. Su red guarda un estado y lo actualiza con cada palabra.



¿Cuántas matrices distintas hay en la cadena?

La red recurrente simple

La misma cadena, ahora con sus pesos

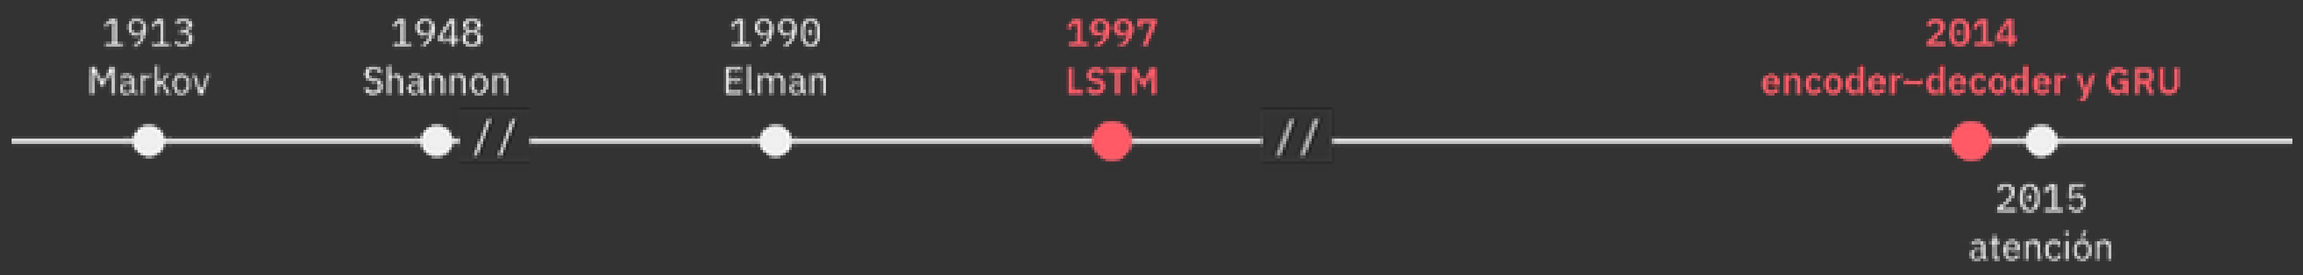


$$h_t = \tanh(W\, x_t + U\, h_{t-1} + b)$$

W, U y b son los mismos en todos los pasos. La red guarda lo que leyó en el estado h_t.

Pregunta 2 de 4

¿Cómo recordamos una palabra lejana?



Desvanecimiento del gradiente

Al entrenar, el error que vuelve hacia «Francia» se multiplica en cada paso por U y por la derivada de tanh, y se achica hasta casi desaparecer (vanishing gradient).



lo que «Francia» aporta al estado se achica en cada paso

LSTM y GRU

Una compuerta es un vector de valores entre 0 y 1, calculado en cada paso, que regula qué se conserva, qué se escribe o qué se muestra.

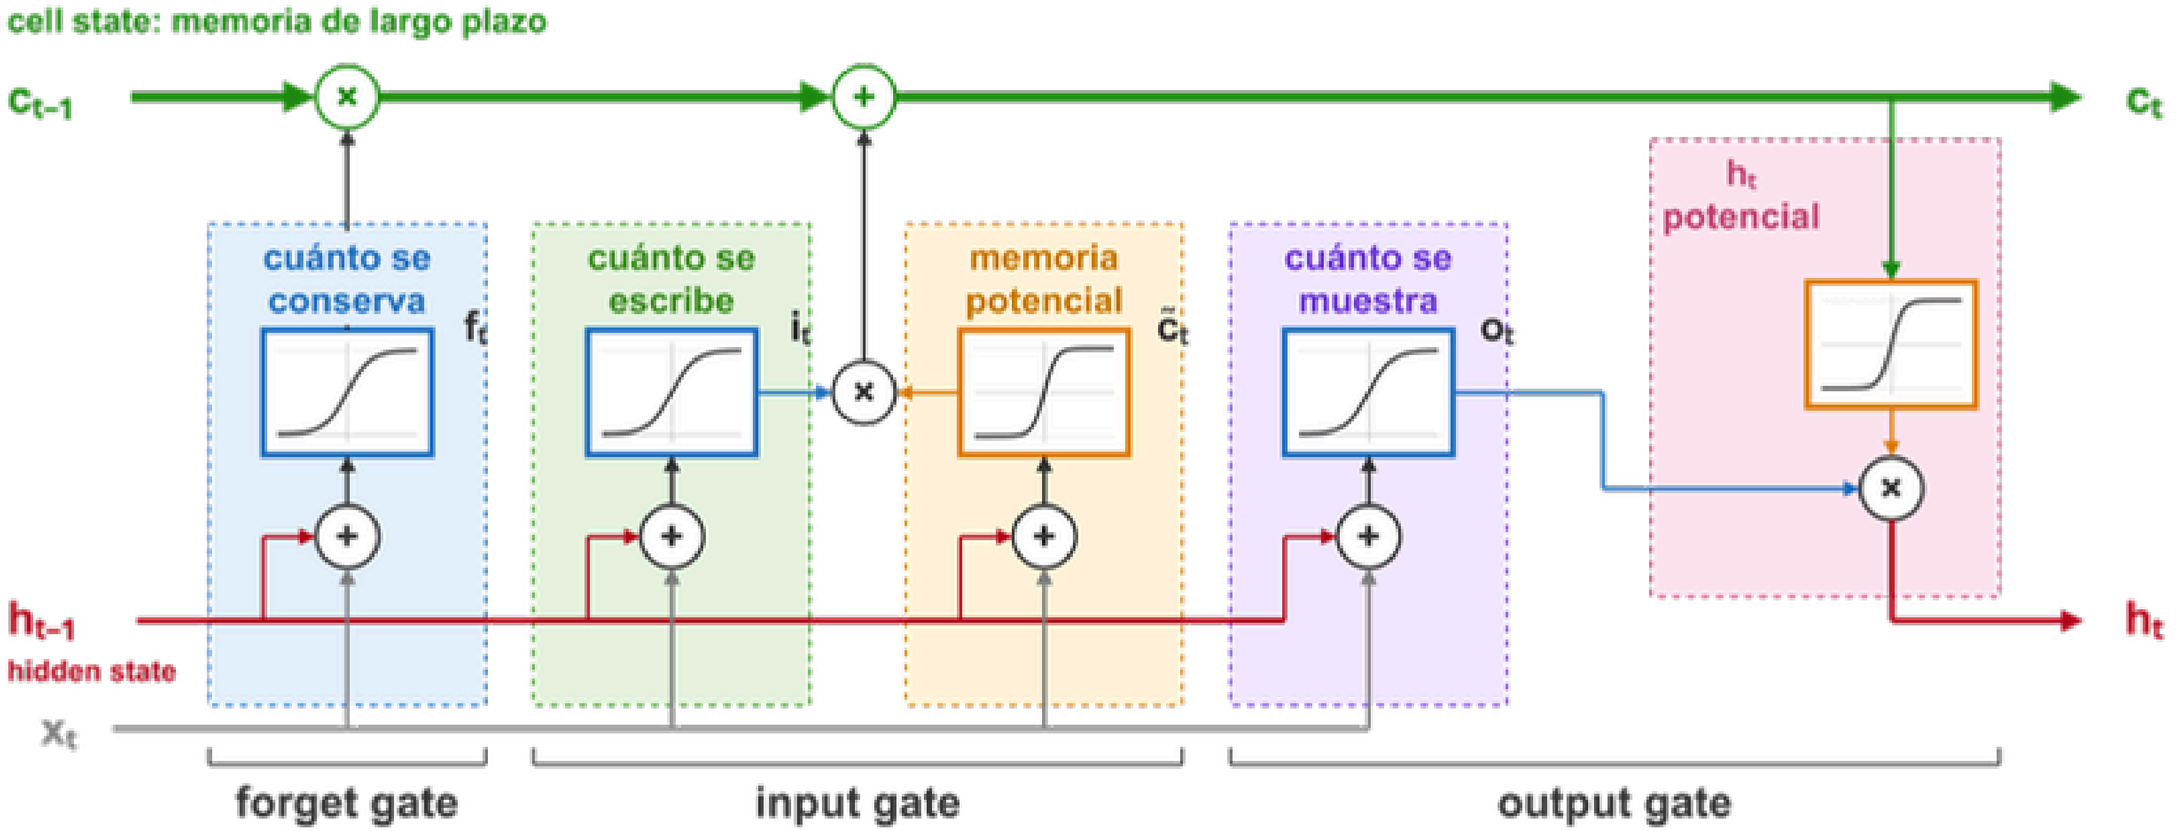


Diagrama adaptado de Starmer (2022), StatQuest

LSTM y GRU

La GRU tiene una sola línea, h, y dos compuertas. La update gate z_t decide cuánto de h se conserva; la reset gate r_t, cuánto de h se usa para calcular el candidato.

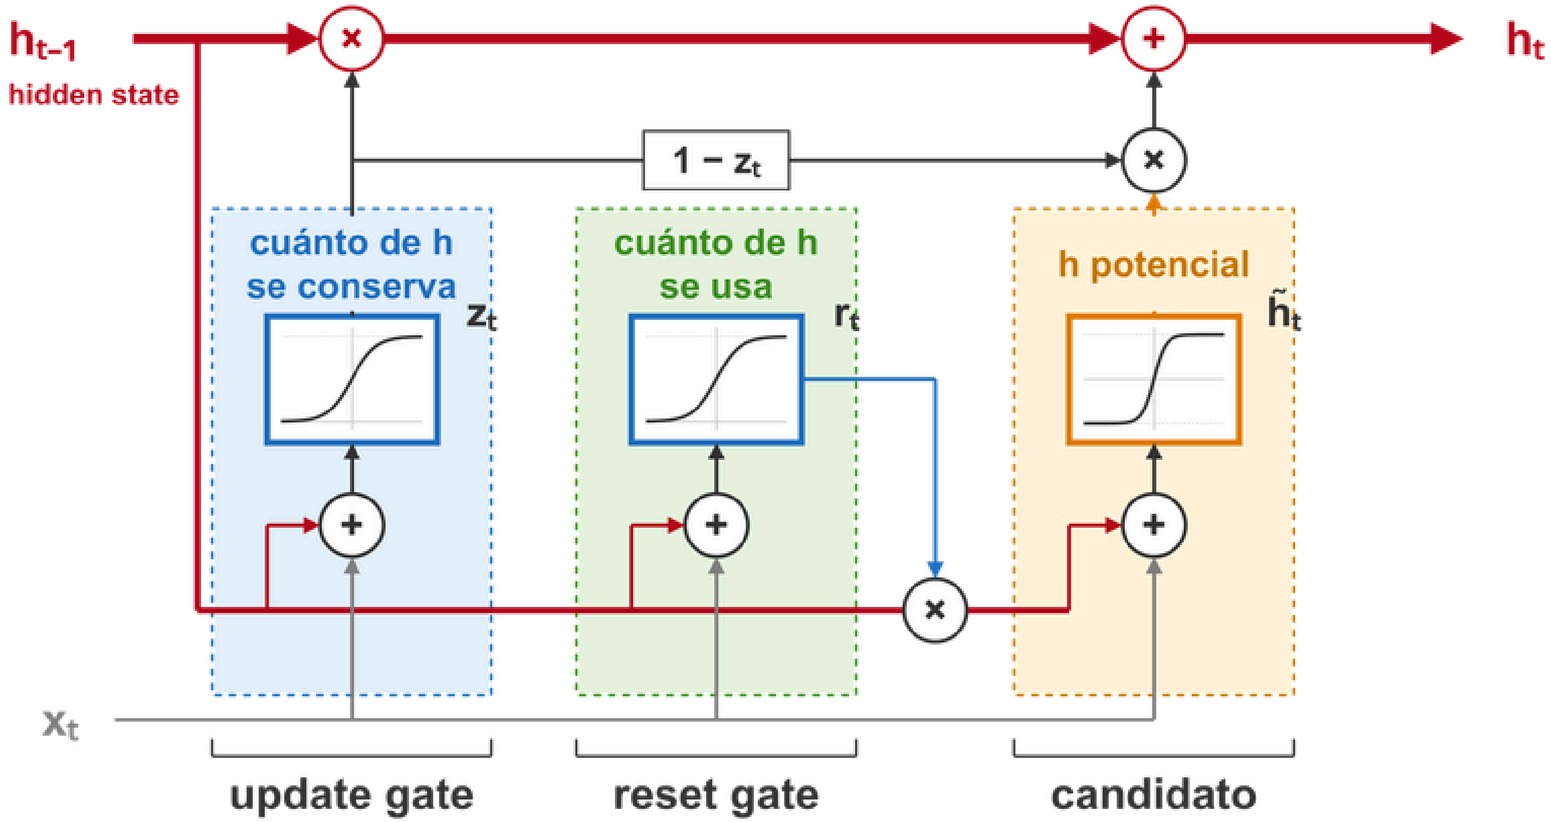


Diagrama adaptado de Starmer (2022), StatQuest

Pregunta 3 de 4

¿Cómo producimos una salida de otro largo?

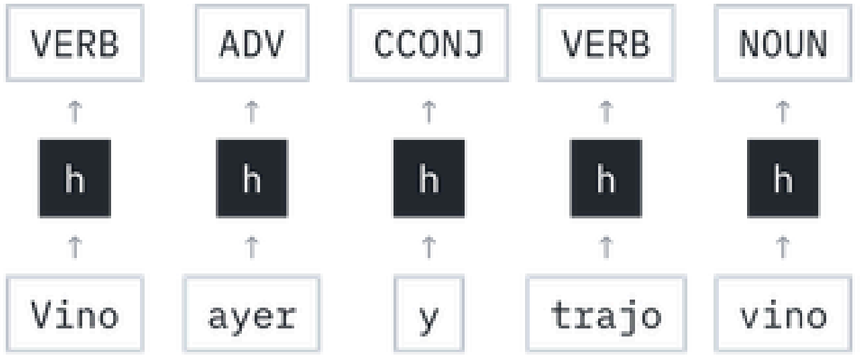


Usos de una red recurrente

1. una salida por texto: clasificar



2. una salida por palabra: etiquetar

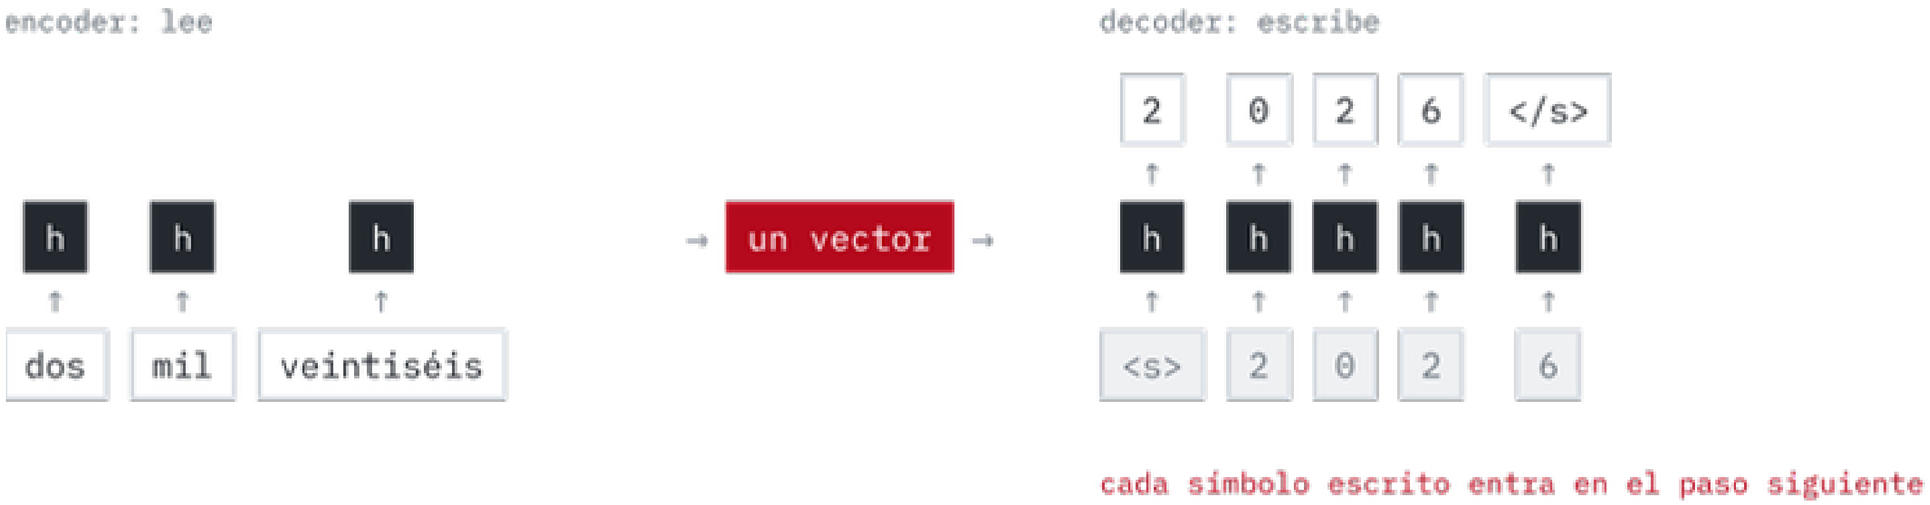


3. una secuencia de otro largo: encoder-decoder



Encoder–decoder

Al traducir, la entrada y la salida tienen largos distintos. «dos mil veintiséis» tiene tres palabras y 2026 tiene cuatro dígitos.



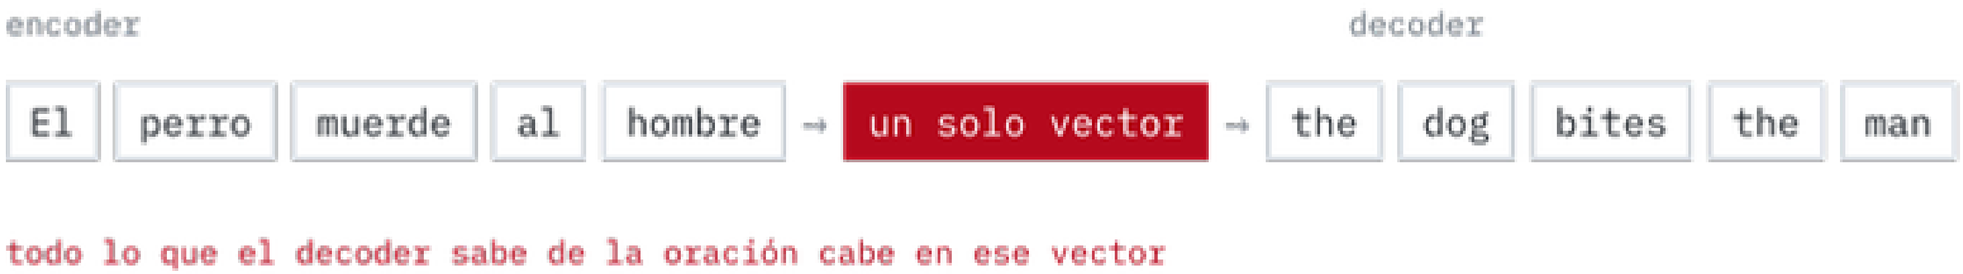
En 2014, un equipo de Google propuso usar dos redes recurrentes. Una lee la entrada y la resume en un vector; la otra escribe la salida a partir de ese vector, un símbolo a la vez.

Pregunta 4 de 4

¿Qué pasa cuando todo tiene que caber en un solo vector?



Encoder–decoder



En el notebook, el traductor acierta con frases cortas y pierde contenido en las largas.

Al notebook

Un clasificador de punta a punta contra un baseline, cómo elegir la red, un etiquetador y un traductor.

Referencias

Bahdanau, D., Cho, K. y Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. ICLR 2015. arXiv:1409.0473.

Bengio, Y., Simard, P. y Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. IEEE Transactions on Neural Networks, 5(2), 157–166.

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. y Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. EMNLP 2014, 1724–1734.

Elman, J. L. (1990). Finding structure in time. Cognitive Science, 14(2), 179–211.

Franz, A. y Brants, T. (2006). All our n-gram are belong to you. Google Research Blog, 3 de agosto de 2006.

Gers, F. A., Schmidhuber, J. y Cummins, F. (2000). Learning to forget: Continual prediction with LSTM. Neural Computation, 12(10), 2451–2471.

Hochreiter, S. (1991). Untersuchungen zu dynamischen neuronalen Netzen. Tesis de diploma, Technische Universität München.

Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780.

Jurafsky, D. y Martin, J. H. (2026). Speech and Language Processing (3.ª ed., borrador del 19 de agosto de 2026), caps. 3 y 14.

Markov, A. A. (1913). Un ejemplo de investigación estadística del texto de Eugenio Oneguin que ilustra la conexión de pruebas en cadena. Trad. inglesa en Science in Context, 19(4), 591–600 (2006).

Olah, C. (2015). Understanding LSTM networks. colah.github.io.

Shannon, C. E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27, 379–423, 623–656.

Starmer, J. (2022). Long Short-Term Memory (LSTM), Clearly Explained. StatQuest (YouTube).

Sutskever, I., Vinyals, O. y Le, Q. V. (2014). Sequence to sequence learning with neural networks. NeurIPS 2014.